

2018. 11. 27. 제2018-006호

인공지능, 어디까지 왔나?

추형석 선임연구원[†]

- 본 보고서는 「과학기술정보통신부 정보통신진흥기금」을 지원받아 제작한 것으로 과학기술정보통신부의 공식의견과 다를 수 있습니다.
- 본 보고서의 내용은 연구진의 개인 견해이며, 본 보고서와 관련한 의문사항 또는 수정·보완할 필요가 있는 경우에는 아래 연락처로 연락해 주시기 바랍니다.
 - 소프트웨어정책연구소 기술·공학연구실 추형석 선임연구원(hchu@spri.kr)

《 Executive Summary 》

현대 인공지능 기술의 발전 속도는 매우 빠르다는 것에 의심할 여지가 없다. 이 사실은 한편으로 최신 인공지능 기술을 제대로 파악하기조차 어렵다는 것을 대변한다. 또한 인공지능의 적용이 다양한 산업에 이르러 범용 목적 기술(General Purpose Technology)로 주목받자 그 경계가 모호해졌다. 예를 들어, 빅데이터 분석과 인공지능의 차이는 무엇일까? 방법론의 차이일까? 현대 인공지능의 중추인 학습 기반의 인공지능은 필연적으로 빅데이터를 요구한다. 성공적인 인공지능 시스템을 구축하기 위해서는 양질의 데이터가 다다익선이다. 이러한 관점에서 빅데이터와 인공지능은 서로 다른 분야로 구분 짓기 어렵다고 본다.

인공지능 기술을 발전상을 이해하려면 인공지능 연구의 특성별로 구분지어 바라볼 필요가 있다. 그러나 인공지능의 적용 범위가 지속적으로 확장되고, 인공지능을 주도하는 주체가 글로벌 IT 기업이라는 관점에서 일목요연하게 구분 짓기는 어렵다. 또한 국제적인 시장조사기관의 분류체계 역시 매우 상이하기 때문에, 참고문헌을 기반으로 한 기술의 분류는 한계가 있다. 이 보고서에서는 인공지능 연구 분야의 구분을 위해가설을 통한 접근을 취했다. 이것은 인공지능 기술의 굵직한 트렌드를 바탕으로 인공지능을 바라보는 관점을 제시한다.

그렇다면 현재 인공지능 기술은 어디까지 왔을까? 이 보고서에서는 지난 2017년 AlphaGo Zero 이후 인공지능 연구계에서 공개된 주요 연구 성과를 살펴볼 것이다. 특히 인공지능 자체의 성능을 향상시킨 연구를 분석했다. 현재 심층학습(Deep learning)은 매우 좋은 성능을 보이고 있으나, 여전히 좁은 인공지능, 약인공지능에 머물고 있다. 이를 개선하기 위한 노력으로 학습하는 방법을 학습하는 메타 학습 분야가 부상하고 있다. 또한 최적의 인공신경망 구조를 찾는 신경망 구조 탐색, 뉴로모픽칩에 탑재되는 스파이킹 신경망, 마지막으로 도메인 간 지식을 전이하는 전이학습을 살펴볼 것이다.

인공지능은 지금도 빠르게 그 영역을 확장하고 있다. 이 보고서에서 다룬 내용은 특히 인공지능의 성능 자체를 향상시키는 연구결과에 집중했다. 다양한 산업계에서 인공지능의 성공사례는 지금도 속속들이 나오고 있을 것이다. 인공지능의 거대한 조류 속에서 인공지능의 기술적 발전에 대한 시의성 있는 분석이 매우 중요한 시점이다.

《 Executive Summary 》

There is no doubt that the speed of modern artificial intelligence (AI) technology is very fast. This, on the other hand, means that it is difficult to grasp the latest AI technology. In addition, the application of AI came to various industries and became a general purpose technology. For example, what is the difference between big data analysis and AI? Is it a difference in methodology? Learning-based AI, the backbone of modern artificial intelligence, inevitably requires big data. In order to build a successful artificial intelligence system, high-quality data is the more the better. From this point of view, big data and AI are hard to distinguish from each other.

To understand the evolution of AI technology, a good classification of technology is needed. However, it is difficult to propose a clear classification system from the viewpoint that the major player of AI is a global IT company, and the range of application of AI is continuously expanding. In addition, since the classification of international market research institutes is also very different, there is also a limit to the construction of classification based on references. In this report, we took a hypothetical approach to suggest a classification of AI technology. This suggests the viewpoint of AI based on the big trend of AI technology.

So where is AI now? In this report, we will look at the major research achievements published in the AI research community since Alpha Go Zero in 2017. In particular, we analyzed the research that improved the performance of artificial intelligence itself. Deep learning is currently performing very well, but it is still in the narrow AI. There is an emerging field of meta learning that learns how to learn in an effort to improve it. In addition, we will explore neural architecture structure search for optimal neural network structure, spiking neural network in neuromorphic chip, and finally transfer learning to transfer knowledge between domains.

AI is still expanding rapidly. The report focuses on research that specifically improves the performance of AI. The success stories of AI in various industries are still on-going. A timely analysis of the technological development of AI is very important.

《 목 차 》

1. 서 론	1
(1) 배 경	1
(2) 심층학습의 한계	3
2. 인공지능 기술 발전의 트렌드	5
(1) 인공지능 R&D와 산업의 특징	5
(2) 인공지능 연구 영역의 구분	8
3. 인공지능 최신 연구 현황	12
4. 결 론	24

《 Contents 》

1. Introduction	1
(1) Backgrounds	1
(2) Limitations of Deep Learning	3
2. A Trend of AI Developments	5
(1) Characteristics of AI R&D and Industry	5
(2) Classification of AI Research Fields	8
3. Recent Trends of AI researches	12
4. Conclusions	24

1. 서 론

(1) 배 경

인공지능은 21세기 들어 가장 혁신적인 기술이다. 현재 인공지능의 상승세는 무섭다. 당장 우리와 밀접한 관련이 있는 제품이나 서비스에 인공지능이라는 단어가 출현하고 있기 때문이다. 그렇다면 인공지능은 기술의 범위는 어디까지 일까? 인공지능이라는 개념은 1956년 다트머스 회의에서 최초로 정립됐다. 당시의 인공지능은 사람의 지능을 모사하는 기계장치로 사람처럼 언어로 소통하고 문제를 해결할 수 있다는 개념이었다.¹⁾

그러나 사람의 지능의 실체는 여전히 모호하다. 지능은 인간과 동물을 구분짓는 잣대로 활용하고 있으나, 동물들 역시 생존을 위해 지속적으로 학습한다. 반면 인간은 가치를 위해 학습하고 적용하기 때문에, 더 고차원적인 지능 활동을 한다고 볼 수 있다. 따라서 인공지능의 궁극적인 목표는 다트머스 회의에서 언급됐듯이 사람과 유사한 혹은 사람 수준의 기계장치 개발에 있다. 하지만 사람의 지능적 행동은 그 원리에 대한 가설은 있으나 아직 실험적으로 규명되지 않았다. 예를 들면, 사람의 동기(motivation), 의식(consciousness), 감정(emotion) 등 지능의 밑바탕이 되는 요소들에 대한 가설이 존재할 뿐 모사가 어려운 상황이다. 이에 따라 현재 인공지능은 사람 수준의 지능을 구현하기보다, 지능적 행동의 일부를 모사하는데 그치고 있다. 그러나 이것조차 과거 60여 년 간의 인공지능 역사에서는 매우 어려운 과제였다.

이러한 상황에서 심층학습(Deep Learning)의 등장은 현대 인공지능 기술의 지평을 바꿔 놨다. 바둑 인공지능 프로그램 AlphaGo에서 소개된 것처럼, 심층학습은 바로 빅데이터를 학습해 패턴을 인식하는 기술이다. 심층학습은 1980년대를 풍미한 인공지능 기술인 인공신경망(Artificial Neural Network)을 기반으로 한다. 인공신경망은 동물의 신경망 구조를 모사한 개념으로, 자극에 의한 정보 전달과 헵(Hebb)의 이론²⁾에 근거한다.

1) The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. (Dartmouth workshop, Wikipedia)

2) 두 뉴런 사이의 정보전달이 빈번하게 일어나면 그것들을 연결하는 시냅스가 강화된다(더 쉽게 정보를 전파한다)는 이론

심층학습의 성공 사례는 매우 다양하다. 우리가 접하는 스마트 스피커의 음성 인식, 포털 사이트의 기사 추천, 자율주행차의 주변 환경 인식, 기계 번역 등 다양한 사례가 있다. 그 원천은 데이터다. 데이터가 인공지능이라는 분석 도구를 만나 그 가치가 높아진 것이다. 여기서 인공지능의 주요한 쓰임새를 찾을 수 있다. 인공지능의 본질적인 목표는 인간 수준의 지능을 구현하는 것이나, 현재는 복잡한 데이터에서 패턴을 탁월하게 인식하는 기술로 활용되고 있다는 것이다. 즉 심층학습을 도구로 데이터에서 의미 있는 결과를 도출하는 것이 현대 인공지능에서 주류를 이루고 있는 접근이다. 여기서 주목할 점은 심층학습에 적용될 수 있는 데이터의 종류가 상당히 폭넓다는 것이다. 이러한 특징으로 인해 인공지능이 범용 목적 기술(General Purpose Technology)³⁾로 부상하고 있는 것이다.

따라서 인공지능은 대량의 데이터가 생성되는 분야면 적용될 가능성이 높다. 사회관계망서비스, 인터넷 상거래, 금융 거래, 병원 처방 등 우리의 행동이 모두 데이터로 기록되고, 이를 활용해 다양한 산업적 활용이 가능하기 때문이다. 이러한 관점에서 다시 첫 번째 질문이었던 “인공지능 기술의 범위”를 상기시켜 보면, 이에 대한 답은 쉽게 내리기가 어렵다. 인공지능의 적용은 그 범위가 넓을 뿐만 아니라 급속도로 확장되고 있기 때문이다. 또한 SW를 통해 문제를 해결하는 접근이 대중화됨에 따라 시스템의 일부에서 인공지능이 활용되는 경우가 대부분이기 때문에, 어떠한 제품에서 인공지능이 차지하는 비중을 산정하기에도 쉽지 않다.

인공지능 기술 자체에서도 그 범위가 모호함을 찾을 수 있다. 현재 우리 산업과 사회가 인식하고 있는 인공지능은 심층학습이다. 심지어는 인공지능을 심층학습과 동치의 개념으로 사용하는 사례도 적지 않다. 바로 심층학습의 성능이 그간의 인공지능 방법론을 압도할 정도로 높기 때문이다. 그러나 심층학습이 만능은 아니기 때문에 현재 심층학습이 겪고 있는 한계에 대해 살펴볼 것이다.

그렇다면 현재 인공지능은 어디까지 왔을까? 이 보고서의 목적은 인공지능 연구의 최신 동향을 쉽게 전달하는 데 있다. 앞서 언급한대로 인공지능의 기술의 범위가 매우 폭넓기 때문에, 어떠한 인공지능 연구의 최신 동향을 다루는 가에 대한 기준도 필요한 실정이다. 이 보고서는 분석하고자 하는 인공지능 연구의 대상을 구체화하기 위해 인공지능 연구 분야를 구분하는 관점을 제시할 것이다.

3) 여기서 의미하는 범용은 심층학습이라는 기술 자체가 범용성이 있는 것이 아니라, 음성, 이미지, 신호 등 다양한 데이터를 인공지능망으로 학습할 수 있다는 의미임

(2) 심층학습의 한계

심층학습은 만능이 아니다. 심층학습은 단어 자체에서도 찾을 수 있듯이 데이터를 학습하여 패턴을 인식하는 기술이다. 따라서 데이터 수급과 관련된 문제는 곧 심층학습의 한계와도 맞물려 있다. 또한 기술적으로도 불완전한 점이 존재한다. 이번 절에서는 심층학습의 한계를 크게 세 가지 관점에서 논의해 보겠다.

첫 번째 한계는 심층학습의 학습(training) 데이터와 시험(testing) 데이터의 분포다. 일반적으로 심층학습의 성능을 측정할 때는 시험 데이터의 예측 성능을 활용한다. 그러나 보통 시험 데이터는 전체 데이터의 일부를 활용한다. 다시 말하자면, 전체 데이터가 100이라고 가정 할 때, 학습에는 80이 활용되고 나머지 20을 시험 데이터로 사용한다는 것이다. 바로 이 부분이 학습-시험 데이터가 동일한 분포에서 나왔다는 것을 의미한다. 이것이 시사하는 바는 무엇일까? 예를 들어 시뮬레이션 환경에서 로봇 팔이 물체를 집는 알고리즘을 심층학습을 활용해 구현했다고 보자. 여기서 시험 데이터가 여전히 시뮬레이션 환경에서 생산됐다면, 학습된 인공지능이 물건을 집는 행위를 잘 처리할 수 있을 것이다. 그러나 이 인공지능을 실제 로봇 팔에 적용한다면 필연적으로 실패할 가능성이 높다. 그 이유는 시뮬레이션 환경과 실제 환경이 매우 다르기 때문이다. 실제 환경에서는 중력, 공기와의 마찰, 관성, 기계의 갑작스런 오작동 등 고려해야 할 요소가 매우 많다. 따라서 실제 환경에 적용하기 위해서는 학습 데이터를 실제와 가깝게 구현하던가, 시뮬레이션 환경을 실제에 가깝게 구성해야 할 필요가 있다. 어느 쪽도 만만치 않다. 또 다른 예로는, 고전게임기 ATARI 2600의 벽돌깨기(breakout) 게임을 구현한 강화학습에서도 찾을 수 있다. 벽돌깨기 인공지능은 게임 인공지능의 혁신적인 결과 중 하나였지만, 벽돌깨기 게임의 명도를 20% 올렸을 때는 제대로 작동하지 않는다. 인간이 보기에는 큰 차이가 아니지만 인공지능이 바라보기에는 전혀 다른 문제라는 것이다.

심층학습의 두 번째 한계는 지속적인 학습이 불가능하다는 점이다. 우리는 흔히 인공지능을 실시간으로 학습할 수 있는 것처럼 오해할 수 있다. 그러나 현재 심층학습의 기술로는 지속적인 학습이 어렵다. 예를 들어 100만 개의 데이터로 학습한 인공신경망 모델이 있다고 가정하자. 여기에 10만 개의 데이터가 추가됐을 때, 이미 학습된 신경망에 추가적으로 10만 개를 학습하여 성능을 더 향상시킬 수 있을까? 이에 대한 결론은 “알 수 없다”가 답이다. 10만 개를 학습하여

성능이 올라갈지, 아니면 110만 개를 다시 학습하여 성능이 향상될지는 알 수가 없다. 효율의 관점에서 봤을 때는 10만 개를 추가적으로 학습하는 것이 타당해 보인다. 그러나 현재는 10만 개를 추가적으로 학습하던 110만 개를 다시 학습하던 일단 시도를 해 보고 선택하는 것이 일반적이다. 이러한 현상의 원인은 인공신경망의 구조적인 특성에서도 유추할 수 있다. 인공신경망을 학습하는 행위는 수학적으로 비용함수의 최소값을 찾는 과정이다. 그러나 비용함수의 차원은 인공신경망의 가중치 개수이며, 보통 수 백 만개를 넘어서기 때문에 결과적으로 수 백 만 차원의 비선형 함수에서 최소값을 찾는 문제로 귀결된다. 보통 5차원만 넘어서도 차원의 저주(curse of dimensionality)로 인해 해석적으로 최소값을 구하기 어렵고, 수치적인 근사로 찾는 방법이 일반적이다. 따라서 100만 개로 학습한 최적의 인공신경망을 10만 개로 추가 학습한다고 해도 의미 있는 결과를 보장할 수 없다.

심층학습의 세 번째 한계는 설명가능성이 낮다는 점이다. 현재 심층학습의 성능은 비록 설명이 불가능해도 학계에서 받아들여지고 산업계에 활용될 만큼 높다. 그만큼 높은 성능이 현대 인공지능의 붐을 이끈 원동력이다. 그러나 어떠한 방법론을 쓰던 성능이 좋기만 하면 되는 분야가 있는 반면, 그 인과관계를 철저히 규명해야하는 분야도 있다. 예를 들어 자율주행차가 사고를 냈는데, 그 원인을 특히 심층학습에서 찾으려 한다면 매우 어려울 것이다. 그 이유는 현재 심층학습 기술의 설명가능성이 매우 낮기 때문이다. 인공지능의 설명가능성은 보수적인 관점에서 인공지능이 우리의 삶과 공존할 수 있는 마지노선일 것이다. 한편으로는 설명가능성에 집중하기보다, 경험적으로 인공지능을 도입하는 것이 효율적이라면 응당 도입해야 한다는 관점도 있다. 현재 많은 과학기술들은 그 역효과를 철저히 규명하고 보장하기는 어렵다. 기술을 먼저 도입하고 나서 발생하는 문제를 단계적으로 대처해 나가자는 관점이다. 그러나 인공지능이 점점 고도화됨에 따라 인공지능이 인적·물적 피해의 직접적인 원인이 될 수도 있다. 이것이 설명 불가능하여 모든 책임을 단순히 인공지능을 사용한 주체에 부과한다면 매우 부조리 할 가능성이 높으며 사회적 문제를 야기할 것이다.

지금까지 심층학습의 한계에 대해 논의했다. 그렇다면 현재 인공지능 기술은 어디까지 왔을까? 이러한 한계를 극복하기 위한 노력은 어느 정도 진척이 됐을까? 이 물음에 답하기 위해 인공지능 기술의 주요 트렌드와 실제 최신 동향을 분석해 보겠다.

2. 인공지능 기술 발전의 트렌드

본격적으로 인공지능의 최신 연구 현황을 분석하기 앞서, 인공지능 기술 발전의 트렌드를 살펴보고자 한다. 그 목적은 궁극적으로 인공지능 연구의 영역을 객관적으로 구분하고 영역별 로드맵을 제안하는 데 있다. 그러나 현재 단계에서는 먼저 인공지능 연구를 구분하기 위한 가설을 세우는 것으로 출발하겠다. 이 가설에 대한 근거는 인공지능 R&D와 산업의 특징에서 찾아볼 것이다.

(1) 인공지능 R&D와 산업의 특징

다음 <표 1> 인공지능 기술의 주요 특징을 기술한다. 이것은 전문가 회의, 국내외 문헌 자료 등에서 재구성한 것으로 세부적인 내용에 대해 살펴볼 것이다. 이 특징을 바탕으로 인공지능 연구 영역의 구분에 대한 가설을 제시할 것이다.

<표 1> 인공지능 기술의 주요 특징

1. 인공지능 기술의 발전 속도는 매우 빠르다.
2. 인공지능 기술이 적용되는 분야가 빠른 속도로 확장되고 있다.
3. 인공지능 기술을 주도하는 주체는 글로벌 IT기업이다.
4. 현재 인공지능 기술은 약 인공지능(weak AI)에 머물고 있다.

1. 인공지능 기술의 발전 속도는 매우 빠르다. 인공지능의 발전 속도가 매우 빠른 근본적인 이유 심층학습에 대한 연구의 과도한 집중 때문이다. 심층학습은 앞서 소개한대로 한계가 분명한 기술이지만, 매우 높은 성능을 보이고 있다. 그 열기는 아직 지속되고 있으며, 이제 연구계나 산업계를 불문하고 인공지능이라는 키워드를 적극적으로 활용하고 있다. 또한 오픈사이언스 생태계의 확대로 연구결과를 공유하는 arXiv, 개발한 코드를 공개하는 github 저장소, 수 십여 종에 이르는 심층학습 공개SW 등 심층학습이라는 기술의 접근성 자체가 매우 낮아졌다. 또한 심층학습의 설명 가능성을 보장하기 위한 이론적 연구 역시 심층학습의 눈부신 성과로 인해 연구가 집중되고 있다. 예를 들면, 일반적인 인공신경망에서 은닉층(hidden layer)을 3층, 4층으로 구성했을 때의 차이점을 수학적으로 증명하는 내용 등을 다룬다. 이처럼 심층학습의 대성공으로 인한 전 세계적인 연구의 집중은 결국 심층학습의 빠른 발전속도에 기여하고 있다. 한 가지 특이

한 점은 현재 인공지능 연구에서 심층학습이 차지하는 비중은 대략적으로 80% 이상으로 추정된다는 것이다. 따라서 현 시점의 인공지능은 대부분이 심층학습이라는 관점에 이의가 많지 않다. 결국 인공지능 기술의 빠른 발전속도는 곧 심층학습의 방법론 자체의 성능향상에 기여하고 있다. 예를 들면, 적은 데이터로 학습하는 방법, 학습하는 방법을 학습하는 접근(Learning to learn), 설명 가능한 인공지능 등이 이에 속한다고 볼 수 있다. 이러한 접근은 기초·응용·개발의 R&D 단계로 볼 때 기초연구에 속한다.

2. 인공지능 기술이 적용되는 분야가 빠른 속도로 확장되고 있다. 앞서 언급한 대로 현재 인공지능은 대부분 심층학습이 이끌어간다고 볼 수 있다. 심층학습은 매우 다양한 형태로 진화하고 있으나 본질적으로는 분류와 군집에 최적화된 방법론이다. 여기서 분류와 군집은 인식(recognition)과 탐지(detection)의 영역에서 필수적인 요소 볼 수 있다. 인식과 탐지는 컴퓨터 과학에서 대표적으로 컴퓨터 비전, 자연어 처리, 음성 인식, 데이터 마이닝 등의 영역이 속한다. 따라서 심층학습은 인공지능과 관련된 컴퓨터 과학의 영역을 재편했다고 볼 수 있으며, 실제로 언급한 분야에서 높은 성과를 달성했다. 이러한 성과는 곧 타 산업과 연구 영역으로 전파되고 있다. 컴퓨터 비전은 의료 영역에서 암을 진단하고, 자연어 처리는 기계 번역에 적용되며, 음성 인식은 스마트 스피커에 탑재됐다. 또한 많은 데이터가 누적돼있는 기초과학 분야에까지 심층학습이 전파되어 새로운 모델링 기법으로 활용되고 있다. 따라서 인공지능 기술의 지속적인 확대는 심층학습을 실제 응용 분야나 타 산업에 접목시키는 것으로 해석할 수 있다. R&D 단계에서 볼 때는 응용·개발연구의 영역이 혼합되어 있는 양상이다.

3. 인공지능 기술을 주도하는 주체는 글로벌 IT기업이다. 이 사실에 대해서는 큰 이견이 없을 것이다. 인공지능을 대표하는 글로벌 IT기업은 미국과 중국이 우세한 상황이며, 기술력과 생태계는 미국이 앞서고 있으나 중국이 무섭게 추격하고 있는 흐름이다. 글로벌 IT기업이 인공지능을 주도하고 있는 상황은 기술발전의 측면에서는 이례적이다. 보통 기초학문에서의 새로운 발견이 응용학문으로 이어지고, 이것이 산업계에 전파되는 과정이 일반적이다. 그러나 인공지능은 산업계에서 주도하고 있으며 이것이 역으로 기초학문에 영향을 미치고 있다. 이러한 이유로 이론적 접근보다는 실증적인 접근이 받아들여진다고 볼 수 있다. 이론적으로 탄탄한 배경보다는 실제 문제해결의 가능성에 집중하고 있는 인공지능의 활용은 곧 SW의 속성과도 일맥상통한다. SW는 승자독식의 원리가 적용되는

대표적인 분야로, 인공지능 역시 아직 승자는 없는 상황이나 승자를 차지하기 위한 경쟁이 본격화 되고 있다. 그 중심에는 플랫폼이 있다. 인공지능의 플랫폼화 전략에 단연 앞서있는 기업은 구글이다. 구글은 심층학습 공개SW, 클라우드 서비스에서도 후발주자였다. 심층학습에서는 텐서플로를 공개하기 이전 카페(Caffe)나 토치(Torch)와 같은 공개SW가 이미 선점을 하고 있었으며, 클라우드는 아마존 웹 서비스가(AWS)가 시장의 대부분을 차지하고 있었다. 이 상황에서 구글은 기계학습 클라우드 플랫폼(Machine Learning Cloud Platform)을 서비스하여 활로를 모색했다. 구글의 텐서플로로 작성된 소스코드는 구글의 대규모 클라우드에 활용할 수 있으며, 최근에는 데이터를 기반으로 최적의 학습 모델을 제공하는 AutoML을 출시했다. 비단 기계 학습 자체뿐만 아니라 고성능 OpenAPI⁴⁾도 지원하고 있다. 이처럼 인공지능을 둘러싼 글로벌 IT 기업의 경쟁은 곧 플랫폼의 전쟁으로 확산되고 있다.

5. 현재 인공지능 기술은 약 인공지능(weak AI)에 머물고 있다. 심층학습이 눈부신 성과를 거두고 있으나 기술적인 관점에서 현재 인공지능은 약 인공지능에 머물러 있다. 즉, 인간의 특정한 지능을 모사하는 것은 잘 하지만 여러 가지 지능을 단일 시스템으로 모사하지는 못한다는 것이다. 이를 극복하기 위한 연구는 현재 진행 중에 있다. 많은 연구자들이 심층학습이 그 돌파구를 열 것이라고 기대하고 있으나, 전통적으로 인간의 지능의 실체에 대해 연구해 온 뇌과학, 인지과학, 심리학 등의 분야에서는 여전히 범용 인공지능의 길은 어렵다고 추정한다. 감정(emotion)을 예로 들어보자. 현재 심층학습에서는 사람의 표정으로 감정을 예측하는 기술로 소위 감성 지능을 구현하기 위해 노력하고 있다. 그러나 심리학자, 뇌과학자의 관점에서의 감정은 다르다. 사람은 기뻐도 무표정 할 때가 있으며, 슬플 때 도리어 웃는 경우도 있기 때문이다. 이러한 것이 구현되려면 감정에 대해 탄탄한 이론적인 연구가 선행되지 않고서는 불가능하다는 입장이다. 그럼에도 불구하고 세 번째 황금기를 맞이한 인공지능의 관심은 여전히 현재 진행형이다. 인공지능 기술에서 단연 선두를 달리고 있는 미국은 차세대 인공지능 AI Next Campaign을 추진하며 20억 달러를 투자한다고 밝혔다. 미국의 뒤를 바짝 추격하고 있는 중국 역시 2017년 차세대 인공지능 발전계획을 발표하며 범용 인공지능 개발에 대한 적극적인 의지를 보이고 있다. 현재 심층학습을 비롯한 인공지능 기술은 약 인공지능에 머물고 있으나 이를 극복하기 위한 차세대 인공지능 연구가 추진되고 있다고 볼 수 있다.

4) 시각 지능, 기계 번역, 음성 인식 등

지금까지 인공지능 R&D와 산업의 특징으로 다섯 가지를 논의했다. 이 특징들을 바탕으로 도출한 시사점은 다음 <표 2>와 같다. <표 2>는 다음 절에서 제시할 인공지능 연구 영역 구분의 근거자료로 활용될 것이다.

<표 2> 인공지능 기술의 주요 특징과 시사점

- | |
|---|
| 1. 인공지능 기술의 발전 속도는 매우 빠르다.
→ 인공지능 자체의 성능 향상을 위한 인공지능 기초 연구 |
| 2. 인공지능 기술이 적용되는 분야가 빠른 속도로 확장되고 있다.
→ 인공지능을 도구로 활용하는 응용·개발 연구 |
| 3. 인공지능 기술을 주도하는 주체는 글로벌 IT기업이다.
→ 인공지능을 둘러싼 글로벌 IT 기업의 플랫폼 경쟁 |
| 4. 현재 인공지능 기술은 약 인공지능(weak AI)에 머물고 있다.
→ 범용 인공지능 등 차세대 인공지능의 대두 |

(2) 인공지능 연구 영역의 구분

인공지능 기술은 앞서 소개했듯이 범용 목적 기술에 가까운 도구적인 속성으로 인해 명확한 기준을 근거로 연구의 영역을 구분하기 어렵다. 또한 해외 기관들이 제시하는 기준[별첨 참고]들은 기술과 산업 분류가 혼재되어 있는 상태라 일관성이 없다. 이 보고서에서는 인공지능 R&D와 산업의 특징을 바탕으로 연구 영역의 구분을 위한 가설을 세워볼 것이다. 먼저 인공지능 연구 영역은 총 네 가지로 그 정의는 다음 <표 3>과 같다.

<표 3> 인공지능 연구 영역의 구분과 정의

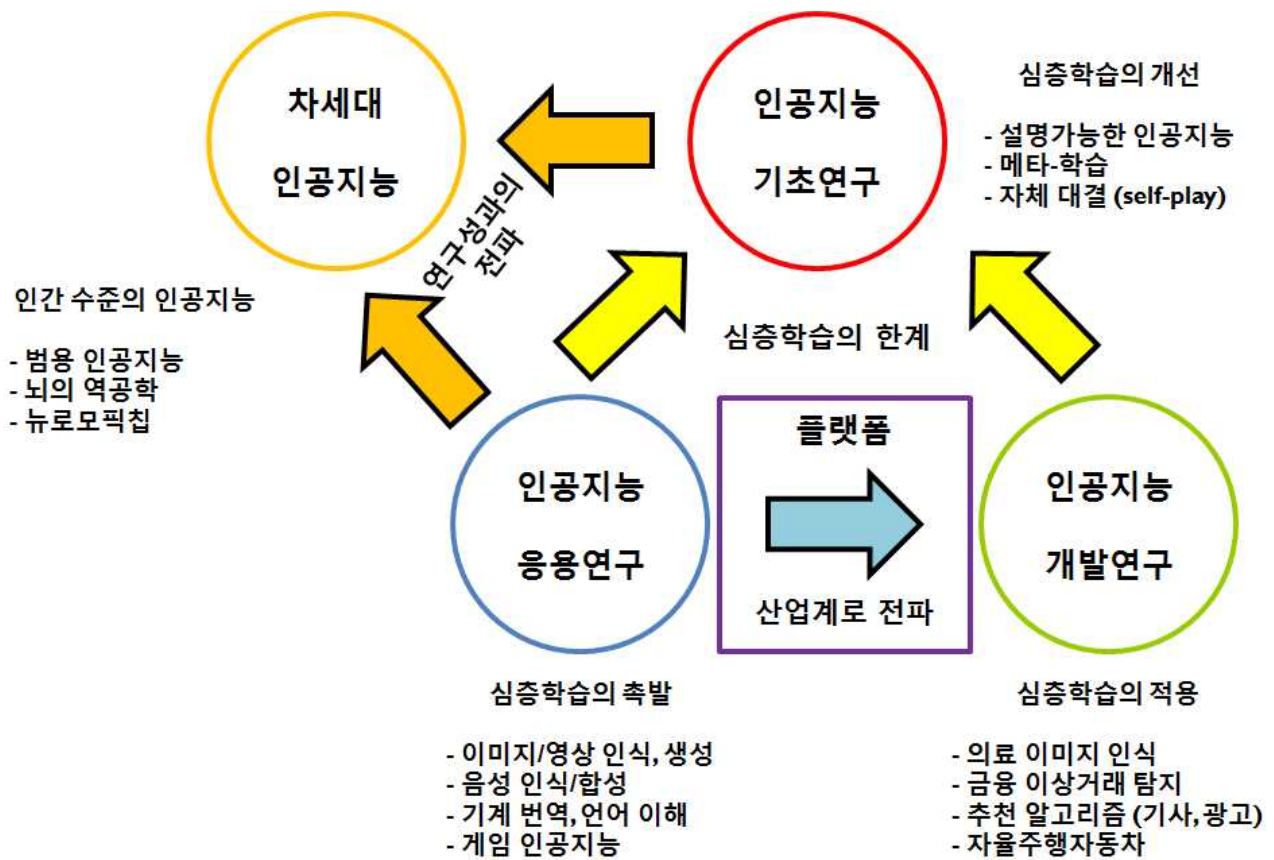
구 분	정 의
인공지능 기초연구	- 인공지능 성능 자체를 향상시키기 위한 연구 (향후 5년) - 예시 : 메타 학습, 설명 가능한 인공지능 등
인공지능 응용연구	- 컴퓨터 과학의 인식 및 탐지 분야 연구 - 예시 : 컴퓨터 비전, 자연어 처리, 음성 인식, 데이터 마이닝 등
인공지능 개발연구	- 인공지능 응용연구가 타 산업에서 활용되는 연구 - 예시 : 의료 이미지에서 암 진단, 금융 이상거래 예측 등
차세대 인공지능	- 사람 수준의 지능을 구현하기 위한 인공지능 연구 (향후 20년) - 예시 : 범용 인공지능, 인공 생명 등

<표 3>에서 인공지능의 연구 단계를 R&D 단계를 차용해서 썼으나, R&D에서 의미하는 기초·응용·개발 연구와는 의미가 일맥상통하지는 않으므로 해석의 유의가 필요하다. 또한 네 가지 영역 명확하게 구분되는 개념은 아니며 서로 교집합이 존재할 수 있다는 사실 역시 감안해야한다. 그것이 인공지능 R&D의 특징이기 때문이다.

<표 3>의 흐름은 다음과 같이 해석할 수 있다. 먼저 심층학습이 본격적으로 성과를 보여주기 시작한 것은 인공지능 응용연구였다. 특히 컴퓨터 비전의 분야에서 인공신경망 기술을 지속적으로 연구했던 결과가 심층학습의 모태가 된다. 심층학습의 4대 석학⁵⁾인 얀 르쿤 뉴욕대 교수는 필기 숫자 인식을 위해 합성곱 신경망(Convolutional Neural Network)을 제안했으며, 심층학습의 창시자인 제프리 힌튼 토론토대 교수는 비지도학습 기반의 심층신뢰신경망(Deep Belief Network)의 개념을 통해 역시 이미지 인식의 성능을 획기적으로 향상시켰다. 따라서 인공지능 응용연구가 혁신을 일으킨 주체가 됐다. 특히 심층학습이 이미지, 음성, 언어 분야에서 괄목할만한 성능이 증명되자 산업계로의 전파가 활발히 이루어졌다. 과거 낮은 인식률로 인해 산업에의 적용이 어려웠던 분야가 점차 활력을 찾기 시작했다. 이는 인공지능 응용연구가 개발연구의 마중물 역할을 했다고 볼 수 있다. 인공지능 개발연구에서도 각 산업계에서 적용한 심층학습의 성과가 두드러지는 반면, 심층학습의 태생적인 한계로 인한 어려움이 발생했다. 바로 서론에서 소개한 심층학습의 한계다. 이를 극복하기 위한 노력이 바로 인공지능 기초연구라고 볼 수 있다. 플랫폼은 인공지능 응용연구가 개발연구로 빠르게 확산시키는 윤활유 역할을 하며, 차세대 인공지능은 인공지능의 개념이 태동했을 때부터 이어온 범용 인공지능 개발을 목표로 하는 것이다. 특히 차세대 인공지능은 심층학습의 성과에 힘입어 심층학습 기반의 범용 인공지능 개발에 집중하는 경향이 대두됐다. 이러한 관점에서 차세대 인공지능 연구는 인공지능 기초연구와도 맞물려 있다.

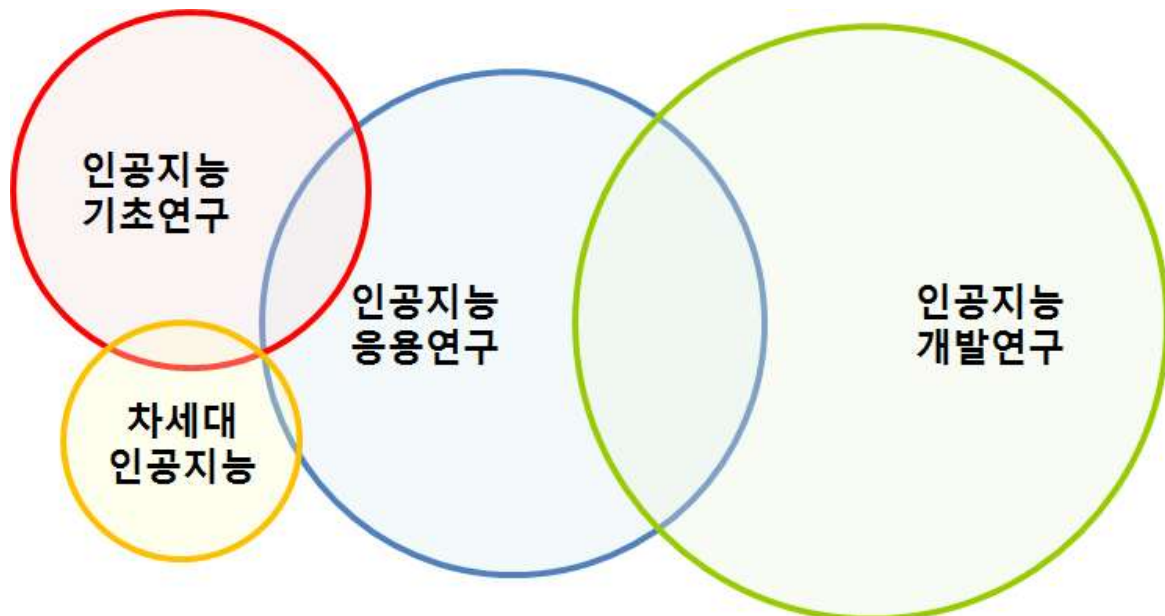
이 흐름을 도식화하면 다음 [그림 1]과 같다. 심층학습은 인공지능 응용연구에서 촉발되어 인공지능 개발연구에 빠르게 적용됐으며, 심층학습의 한계를 극복하기 위한 기초연구가 이루어지고 있다. 플랫폼은 인공지능 응용연구와 개발연구의 간극을 이어준다.

5) 2015년 Nature지에 게재된 Deep Learning의 저자 얀 르쿤(Yann Lecun), 요슈아 벤지오(Yoshua Bengio), 제프리 힌튼(Geoffrey Hinton) 교수와 스탠포드 대학 교수인 앤드류 응(Andrew Ng)



[그림 1] 인공지능 연구 영역의 상관관계

<표 3>을 도식화하면 다음 [그림 2]와 같다.



[그림 2] 인공지능 연구 영역 구분의 도식화

[그림 2]의 해석은 다음과 같다. 먼저 인공지능 연구 영역의 도식화는 가설 단계임을 고려해야 한다. 먼저 인공지능 응용연구와 개발연구는 그 경계가 모호할 수 있으나, 인공지능 개발연구가 대부분 인공지능 응용연구 결과를 차용한다는 가정으로 구분 지을 수 있다. 물론 개발연구의 결과가 응용연구에 직·간접적으로 영향을 미칠 수도 있다. 인공지능 기초연구는 인공지능 응용연구의 성과를 향상시킬 수 있다는 점에서 서로 교집합이 존재한다. 또한 반대로 응용연구에서 직면한 난제를 해결하기 위해 기초연구의 주제를 제시할 수 있다. 차세대 인공지능은 기초연구와 응용연구 모두와 관련이 있으나, 현 시점에서 도전적인 과제를 수행하기 때문에 상당부분 독립된 연구라고 볼 수 있다. 플랫폼은 인공지능 응용연구와 개발연구의 유기적인 전과를 위한 개념으로 본다면 보조적인 기능을 수행한다.

[그림 2]에서 연구영역을 원으로 표현했는데, 원의 크기는 현재 인공지능과 관련된 연구의 비중을 말한다. 이 도식화는 아직 가설을 세우는 단계로 원의 크기는 지속적인 연구를 통해 조정될 수 있다. 특히 어떠한 인공지능 연구가 어느 원에 속하는지 혹은 교집합에 포함 될 것인지를 통해 원의 배치가 변경되거나 새로운 영역(원)이 추가될 수 있을 것이다.

지금까지 인공지능의 R&D와 산업의 특성을 바탕으로 인공지능 연구 영역의 구분에 대한 가설을 제시했다. 이것을 고도화하기 위해서는 수많은 인공지능 관련 연구들을 대입하고 개선해야 하는 것이 숙제로 남아있다. 비록 가설로 출발하지만 제시한 인공지능 연구 영역의 구분이 심층학습의 여러 방법론과 산업에의 적용까지 모두 아우를 수 있다는 측면에서 의미가 있다고 본다.

3. 인공지능 최신 연구 현황

이제 인공지능이 어디까지 왔을까?의 물음에 답하기 위한 인공지능 최신 연구 현황을 분석해보겠다. 특히 지난 2017년 10월 AlphaGo Zero 이후 어떠한 연구 성과가 있었는지를 주로 살펴보겠다. 다음 <표 4>는 이 보고서에서 분석할 인공지능 연구 결과를 나타내며, 앞서 제시한 인공지능 연구 영역의 구분을 활용했다.

<표 4> 인공지능 최신 연구현황 분석 주제

구 분	주 제
인공지능 기초연구	① 메타 학습 : 학습하는 방법을 학습하는 심층학습 기법 ② 신경망 구조 탐색 : 최적의 인공신경망 구조를 도출하는 방법 ③ 스파이킹 신경망 : 뉴로모픽칩의 학습 방법 ④ 전이학습 : 학습된 신경망을 전이(transfer)하여 활용하는 방법

이 보고서에서는 <표 4>와 같이 총 4개의 주제에 대해 최신 연구 현황을 분석해보겠다. 2장에서 제안한 연구 영역을 기준으로 보면 모두 인공지능 기초연구에 속한다. 인공지능 기초연구를 중점적으로 다루는 이유는 이 분야가 향후 기반연구와 활용연구에 접목되어 성능을 향상시킬 수 있는 기반이 되기 때문이다. 인공지능 기반연구는 적용 분야에 대한 도메인 지식이 상당히 필요하기 때문에 별도의 보고서로 분석해 볼 예정이다. 반면 인공지능 활용연구를 다루지 않는 이유는 먼저 그 범위가 매우 넓고, 활용연구 분야의 대부분은 심층학습의 인공지능이라기보다는 빅데이터를 분석하는 데이터 과학에 가까운 경향이 있기 때문에 제외했다. 차세대 인공지능의 경우는 범용 인공지능을 주제로 발간된 보고서⁶⁾에서 심도 있게 다뤘다.

최신 연구 동향의 분석 범위는 다음과 같다. 먼저 기술이 등장하게 된 배경과 기존 기술과의 차별점, 성능과 적용 가능 분야, 마지막으로 향후 전망을 다룰 것이다.

6) 범용 인공지능의 개념과 연구현황, 소프트웨어정책연구소(2018.07.) <https://spri.kr/posts/view/22231>

(1) 메타 학습

메타 학습(Meta learning)은 교육학에서 나온 메타 인지(Meta cognition)의 개념으로부터 출발한다. 메타 인지는 ‘내가 아는 것과 모르는 것을 즉각적으로 인지하는 것’을 의미한다. 다시 말하자면, 특정 사람이 특정 행위를 하는데 있어 이해하고 있는 부분과 그렇지 못한 부분을 얼마나 인지(cognition)하고 있는가를 판단하는 것이다. 따라서 메타 인지가 높은 집단은 일반적인 집단에 비해 동일한 낮은 환경에서 새로운 문제를 더 잘 해결한다는 실험적 결과가 존재한다.

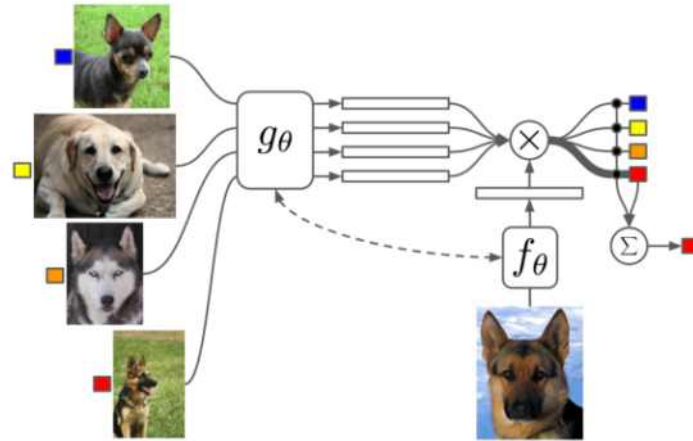
메타 학습은 메타 인지로부터 파생된 개념이다. 메타 학습은 기존에 학습했던 정보를 바탕으로 새로운 문제를 해결하는 접근을 통칭하는 것으로 볼 수 있다. 더 범위를 좁혀 기계학습의 범주에서 메타 학습을 해석하자면, 이것은 기존에 학습한 시스템으로 새로운 임무(task)를 해결하기 위한 방법론을 연구하는 분야다. 여기서 새로운 임무의 범주는 아직 기초적인 수준에 머물러 있어, 이미지를 인식하는 시스템의 경우 새로운 임무 역시 이미지 인식을 의미한다. 아직 이미지 인식 시스템이 음성 인식까지 하기란 요원한 일이다.

더 구체적으로 메타 학습의 배경을 살펴보자. 메타 학습은 일반적으로 학습하는 방법을 학습(Learning to learn)하는 분야를 포괄한다. 현재 연구계에서는 이미 학습된 시스템에 어떻게 새로운 것을 학습시킬 수 있는가를 고민하고 있다. 예를 들면, 100가지 객체를 인식하기 위한 심층학습 모델이 개발되었다고 가정했을 때, 100가지 객체 이외의 새로운 객체를 어떻게 “효율적”으로 학습시킬 수 있는지에 대한 것이다. 여기서 효율적이라는 점은 데이터와 학습 시간의 측면을 의미한다. 따라서 짧은 학습 시간에 적은 데이터를 활용해 효율적으로 학습하는 기법이 메타 학습 분야에서 현재 진행 중인 연구 과제다.

메타 학습의 측정 방법 (Way, Shot)

- 메타 학습의 성능을 측정하는 기준으로 Way와 Shot이라는 단어를 활용하는데, 개념적으로 Way는 분류(Class)의 개수, Shot은 데이터의 수로 볼 수 있음
- 5 Way - 1 Shot의 경우 5개의 분류와 각 분류에 한 개의 데이터가 있는 것으로 이 데이터를 성공적으로 학습하느냐의 여부로 메타 러닝의 성능을 측정
- Shot은 낮을수록(데이터가 적음), Way는 높을수록(분류가 많음) 문제가 어려워짐

메타 학습 중 가장 대중적으로 알려진 원샷 학습(One-shot Learning)은 앞서 Shot의 개념을 살펴봤다시피 한 개의 데이터로 학습하는 방법이다. 다음 [그림 3]은 원샷 학습의 대략적인 구조를 표현한다.



[그림 3] 원샷 학습의 구조도

자료 : Oriol Vinyals, Charles Blundell, Timothy Lillicrap, Koray Kavukcuoglu, and Daan Wierstra, "Matching Networks for One Shot Learning," <https://arxiv.org/abs/1606.04080>

[그림 3]을 토대로 원샷 학습을 살펴보자. [그림 3]에서 원샷 학습의 목표는 네 장의 서로 다른 강아지 이미지를 분류하는 것이다. 그림 상으로는 4 Way - 1 Shot의 문제다. 이 목표를 달성하기 위해 원샷 러닝은 두 가지 함수를 활용한다. 먼저 g_θ 는 이미지에서 특성(feature)을 추출하는 역할을 수행하며, f_θ 는 추론(inference)하는데 활용된다. 일반적으로 g_θ 는 이미지 분류의 기능을 수행하기 위해 이미 학습된 인공신경망(pre-trained network)을 활용하여 특성을 추출한다. 이 특성을 재분류하는 것이 f_θ 의 역할이다. 바로 이미 학습된 신경망이 Way(분류)별로 주어진 Shot(이미지)이 서로 구분될 수 있는 특성을 추출하고, 이것을 군집(clustering)하는 것이 f_θ 라는 것이다.

원샷 학습의 성능은 제한적이지만 이미지 인식 분야에서는 좋은 결과를 나타내고 있다. 그러나 한계점 역시 분명하다. 앞서 소개한 g_θ 는 이미 학습된 신경망이라는 점이다. 또한 g_θ 의 학습(training)에 활용된 데이터와 shot은 어느 정도 유사성이 보장되어야 한다는 것 역시 또 하나의 단점이라고 볼 수 있다.

7) 여기서 특징은 일반적으로 분류층(classifier) 이전에 있는 full-connected 층의 값을 활용함

또 다른 메타 학습으로는 메타 최적화 학습(Meta optimizer learning)이 있다. 기본적으로 인공신경망을 학습한다는 개념은 오차를 역전파(error back-propagation)하여 인공신경망을 구성하는 가중치를 최적화하는 것이다. 여기서 오차는 보통 손실함수(Loss function)으로 정의한다. 손실함수의 가장 큰 예는 특정 학습 단계에 있는 인공신경망의 출력값과 실제값(label)의 차이의 합으로 본다. 메타 최적화 학습은 이 손실함수를 인공신경망으로 구현하는 접근이다. 이것은 메타 손실(meta-loss)라고 정의되며, 이 메타 손실 자체가 낮아지는 방향으로 학습한다면 적은 데이터로도 의미 있는 학습을 할 수 있다는 개념이다.

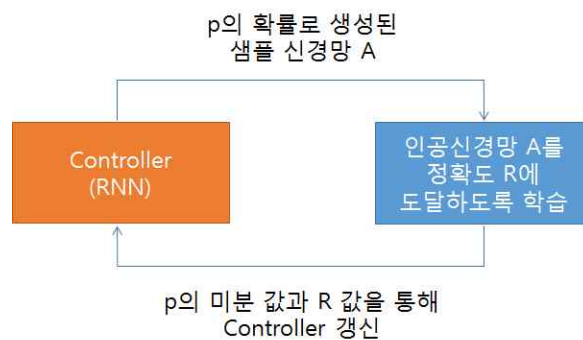
메타 학습은 학습하는 방법을 학습하는 방법론으로 부상하고 있으나, 현재 진행되고 있는 연구 성과로 봤을 때는 여전히 가야할 길이 멀다. 현재 메타 학습의 주요 과제는 학습의 “효율화”다. 심층학습 기술은 그 성능이 매우 뛰어나지만 그 성능을 달성하기 위해 수많은 데이터가 사용됐다는 것은 누구나 인지하고 있는 사실이다. 이에 반해 사람은 적은 양의 데이터로도 일반화시키는 능력이 매우 뛰어나기 때문에, 메타 학습은 이러한 사람의 학습방법을 모방하는 부분에 초점을 두고 있는 것이다. 사실 적은 데이터로 학습할 수 있는 기술이 개발된다면, 심층학습은 새로운 국면으로 진입할 것이다. 그만큼 데이터의 수급이 원활하지 않은 분야가 많으며, 기술 자체에 대한 수요가 높다는 것을 반증한다.

(2) 신경망 구조 탐색

신경망 구조 탐색(Neural Architecture Search, NAS)은 기본적으로 메타 학습의 개념과 비슷하다. 바로 학습하는 방법을 학습하는 것인데, 신경망 구조 탐색이 다른 점은 인공신경망의 구조에 중점을 둔다는 것이다. 최적의 인공신경망 구조는 경험적인 결과를 바탕으로 한다. 구글 AlphaGo의 정책망은 13층의 합성곱신경망을, 페이스북의 딥페이스는 9층의 합성곱신경망을 활용했다. 이처럼 은닉층의 개수와 성능의 상관관계가 불분명한 이유로, 많은 연구자들은 경험적으로 많이 학습해보고 최적의 결과를 도출하는 접근이 일반적이다.

신경망 구조 탐색은 은닉층의 수, 합성곱의 크기와 모수 등 연구자가 변경해가며 학습해보는 방법을 자동화하는 것에 중점을 둔다. 물론 신경망 구조 탐색도 완벽하게 모든 경우의 수를 학습하는 접근은 아니기 때문에, 여전히 귀납적인 접근방법이긴 하나 용이하게 활용할 수 있다는 부분이 장점이다.

신경망 구조 탐색은 [그림 4]와 같이 순환신경망(Recurrent Neural Network)을 통해 파생되는 신경망을 학습하여 최적의 인공신경망 구조를 탐색하는 기술이다. 신경망 구조 탐색에서는 인공신경망을 일종의 다변 문자열(variable-length string)로 구체화한다. 문자열로 표현된 인공신경망(child network) A는 순환신경망의 구조를 갖는 Controller로부터 p의 확률로 생성된다. 인공신경망 A가 학습되고 난 뒤 검증 데이터로 정확도 R을 산출하고, R을 바탕으로 확률 p를 갱신한다. R이 높을수록 최적의 신경망 구조를 찾아간다는 개념이 신경망 구조 탐색의 원리다.



[그림 4] 신경망 구조 탐색의 개념

자료 : Neural architecture search with reinforcement learning에서 재구성

신경망 구조 탐색은 구글이 먼저 제안한 방법론으로 2016년에 처음 소개될 당시 수 백 장의 고성능 GPU를 활용한 결과였다. 말 그대로 귀납적인 방법을 풍부한 계산 자원으로 구현한 것으로 볼 수 있다. 그 결과 모델링을 근거로 한 방법론에 버금가는 성능을 달성했다. 구글은 2018년 효율적인 신경망 구조 탐색(Efficient NAS) 기술을 소개하여 고성능 GPU 한 장만으로도 좋은 성능을 달성함을 <표 5>와 같이 증명했다.

<표 5> 신경망 구조 탐색의 성능

CIFAR-10			Penn Treebank		
방법론	파라미터 수 (백 만)	오차율 (%)	방법론	파라미터 수 (백 만)	혼잡도
경험적인 방법 (DenseNet)	26.2	2.56	경험적인 방법 (LSTM)	22	56.0
NAS	3.3	2.65	NAS	54	62.4
ENAS	4.6	2.89	ENAS	24	55.8

자료 : Pham, Hieu, et al. "Efficient Neural Architecture Search via Parameter Sharing." arXiv preprint arXiv:1802.03268 (2018).


<표 5>에서 시험한 데이터 셋인 CIFAR(Canadian Institute For Advanced Research)-10은 6만 장의 사진을 10개의 종류로 구분한 이미지 데이터로, 이미지 분류의 성능을 측정하는 기준데이터로 활용된다. 파라미터 수는 인공신경망의 가중치 개수를 의미하며 파라미터 수가 작을수록 더 간소한 인공신경망을 의미한다. 신경망 구조 탐색은 이미지 분류 문제에서 기존의 경험적인 방법보다 더 적은 수의 파라미터로도 높은 성능을 달성했음을 확인할 수 있다. 반면 Penn Treebank 데이터셋은 언어 모델의 성능을 측정하는 데 활용된다. 언어 모델은 주어진 문장의 다음에 올 단어를 예측하는 것으로, 측정 기준은 적절함을 판단하는 혼잡도(Perplexity)를 활용하며 낮을수록 성능이 좋다. 마찬가지로 신경망 구조 탐색이 기존의 경험적인 방법에 버금갈 정도임을 증명했다.

구글이 신경망 구조 탐색을 개발한 이유는 최근 출시한 서비스인 AutoML에서 찾을 수 있다. 바로 기업이 심층학습을 적용하기 위한 장벽을 현저히 낮추는 서비스인 것이다. 과거 수 백 장의 GPU가 필요했던 신경망 구조 탐색을 한 장의 GPU만으로도 성공적인 학습이 가능했다는 점 역시 구글의 인프라 운영에도 효율을 높였다. 신경망 구조 탐색은 개인이나 기업이 심층학습을 적용하기 위한 간극을 낮췄다는 점에서 충분히 의미가 있다. 또한 구글이 신경망 구조 탐색을 비롯한 인공지능 기초연구에 몰두하고 있는 이유도 이러한 서비스의 성능을 향상시킬 수 있다고도 해석할 수 있다.

(3) 스파이킹 신경망

스파이킹 신경망(Spiking Neural Network)은 인공신경망과 마찬가지로 신경계의 생물학적 동작 방식을 모사한 방법이다. 그러나 심층학습의 기반이 되는 인공신경망과 스파이킹 신경망은 상당부분 차이가 있다. 첫 번째 차이는 학습하는 방법이다. 인공신경망은 오차 역전파법(error back-propagation)을 활용해 신경망 전체의 가중치를 변경하여 학습한다. 반면 스파이킹 신경망은 세포 수준의 지역적인 학습을 수행한다. 두 번째 차이는 앞서 심층학습의 한계로 언급했던 지속적인 학습에 관한 것이다. 스파이킹 신경망은 구조적으로 인공신경망 보다 우리의 신경계와 가깝기 때문에 연속적인 학습이 가능하다. 세 번째 차이는 학습 시 전력의 소비다. 스파이킹 신경망은 뇌 구조를 모사한 뉴로모픽칩을 학습시키는 데 활용되는 기술이다. 인공신경망은 수백 수천와트를 사용하는 GPU로 학습하는 반면 스파이킹 신경망은 밀리와트로도 학습이 가능하다.⁸⁾

스파이킹 신경망에서 스파이크(Spike)의 의미는 생물학적인 뉴런이 정보를 교환할 때 발생하는 전기적 파동을 말한다. 스파이크 신경망은 세 가지 생물학적 가정을 토대로 제안된 방법이다. 먼저 스파이크 신경망을 구성하는 뉴런은 많은 입력을 받고 하나의 스파이크 신호를 출력한다. 두 번째 가정으로 스파이크가 생성될 확률은 입력이 클수록 증가하고 약할수록 감소한다. 마지막으로 오직 하나의 기준점으로 스파이크 생성 여부를 결정한다. 스파이크를 표현하는 수학적 모델은 디랙-델타 함수이다. 시간에 따라 발생하는 간헐적인 스파이크는 각 스파이크에 해당하는 디랙-델타 함수의 합으로 표현되고, 이 합을 스파이크 트레인(Spike train)이라고 표현한다. 이 스파이크 트레인이 뉴런의 입력과 출력이 된다. 스파이크 신경망의 학습 과정은 특정 두 인공신경세포를 연결하는 가중치를 조정하는 것이다. 이것은 생리학적 학습의 규칙에 따라 시냅스의 연결강도의 변화를 기술한 Hebb의 이론에 기반한다. 쉽게 표현하자면 두 개의 신경세포가 서로 반복적이고 지속적으로 점화(firing)한다면 상호간의 가중치가 강화된다는 것을 의미한다. 가중치의 변화량은 두 인공신경세포의 스파이크 트레인과 스파이크 트레인의 저역통과필터(Low-pass filter)로 구성된다. 이 관계식을 통해 가중치가 변화하고 신경망이 학습된다. 스파이크 신경망의 구조는 다음 [그림 5]와 같다.

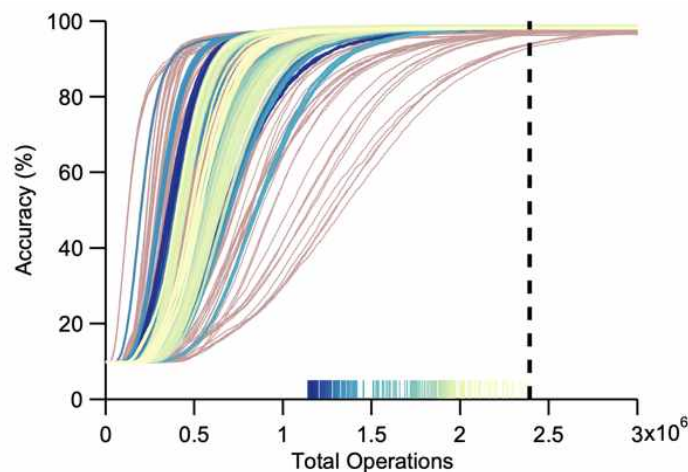


[그림 5] 스파이크 신경망의 구조

자료 : Kulkarni, Santosh, Sishaj P. Simon, and Kinattingal Sundareswaran. "A spiking neural network (SNN) forecast engine for short-term electrical load forecasting." *Applied Soft Computing* 13.8 (2013): 3628-3635.

- 8) ESSER, S. K., et al. Convolutional networks for fast, energy-efficient neuromorphic computing. 2016. Preprint on ArXiv.

이제 스파이킹 신경망의 성능에 대해 살펴보자. 일반적으로 어떠한 시스템을 학습함에 있어 모델 미지수만큼 학습 데이터의 수가 보장되어야 한다. 쉽게 말하자면 연립방정식에서 미지수와 방정식의 관계라고 볼 수 있다. 그러나 그 모델이 인공신경망의 영역에 들어서면 관점이 달라진다. 사람의 뇌는 10^{14} 개만큼의 시냅스(미지수)가 존재하나, 실제로 사용하는 양은 10^9 개 정도이다. 즉, 모든 뉴런이 하나의 정보처리를 위해 사용되는 형태가 아닌 것이다. 이러한 관점에서 스파이킹 신경망은 스파이크 트레인 형태로 정보를 변형하여 학습하기 때문에 연산의 효율 측면에서 강점이 있다. 이것은 저전력의 특성과도 이어지는 부분이다. 아래 [그림 6] MNIST⁹⁾ 데이터 셋에 대해 일반적인 인공신경망과 스파이킹 신경망의 성능을 비교한 그래프다.



[그림 6] 인공신경망과 스파이킹 신경망의 성능 비교

자료 : Tavanaei, Amirhossein, et al. "Deep Learning in Spiking Neural Networks." arXiv preprint arXiv:1804.08150 (2018).

[그림 6]의 x축은 연산의 수, y축은 예측의 정확도를 나타낸다. 검은색 세로 점선은 인공신경망을 활용해 98%의 정확도를 달성하기 위한 연산수이며, 다양한 색의 그래프로 나타낸 것은 스파이킹 신경망을 활용했을 때 연산수에 따른 성능 향상을 나타낸 것이다. 분홍색 그래프는 98% 정확도를 달성하지 못한 경우를 의미하며, 나머지 녹색, 노란색, 파란색은 98%를 달성한 스파이킹 신경망을 의미한다. 종합적으로 볼 때 인공신경망의 연산수 대비해 스파이킹 신경망은 최대 1/4 수준의 연산수만으로도 98%의 정확도를 달성했다는 측면에서 연산의 효율이 높다.

9) Modified National Institute of Standards and Technology database로 손글씨 숫자 10개(0~9)에 대한 6만 장의 학습이미지와 1만 장의 시험이미지로 구성되어, 숫자 인식의 성능 측정을 하는데 기준점이 되는 데이터로 활용됨

스파이킹 신경망의 향후 전망은 크게 두 가지로 볼 수 있다. 먼저 성능 측면에서는 속제가 많다. 현재 동일한 임무에 대해서는 인공신경망의 성능이 더 좋다. 스파이킹 신경망은 기존의 인공신경망에 버금가는 성능은 어느 정도 증명했으나, 인공신경망의 성능을 초월하지는 못한다. 따라서 스파이킹 신경망의 특성을 살린 응용분야를 모색하고 성공사례를 만들어야 할 것이다. 두 번째 전망으로 저전력의 특성을 살리는 접근이 부각될 것이다. 현재 인공신경망을 학습하고 추론하기 위해서는 고성능 계산 자원이 필요하다. 스파이킹 신경망은 저전력으로 구현할 수 있다는 특성으로 학습에 필요한 자원을 획기적으로 낮출 수 있다. 최근 회자되고 있는 엣지(Edge) 컴퓨팅에서 그 영향력을 발휘할 수 있을 것이라 전망된다.

(4) 전이 학습

전이 학습(Transfer Learning)은 이미 학습된 시스템의 지식을 전이(transfer)시켜 새로운 임무를 해결하기 위한 학습 방법을 의미한다. 이것은 도메인 적응(domain adaptation), 일반적인 게임 플레이(general game playing), 다중 임무 학습(multi-task learning) 등 조금 범용적인 인공지능을 연구하는 기계학습 방법론이다. 그러나 2016년부터 심층학습에서 전이 학습이라는 단어를 차용했었는데, 여기서 다루고자 하는 전이 학습과는 다른 것을 먼저 밝힌다.

심층학습의 전이 학습은 이미 학습된 인공신경망(pre-trained network)을 재사용하는 접근이다. 2017년을 끝으로 막을 내린 이미지 인식 경진대회 ILSVRC (ImageNet Large Scale Visual Recognition Challenge)에서는 이미지 분류를 성공적으로 수행한 인공신경망 구조가 공개됐다. 2012년에 우승한 AlexNet, 2015년에 우승한 ResNet이 대표적인 예다. 만약 한 개발자가 새로운 이미지를 분류하는 것을 심층학습으로 구현하고자 한다면, 이미 학습된 AlexNet을 활용하는 것이 심층학습에서의 전이 학습이다. 혹은 이미 학습된 신경망을 조금 변형한다는 측면에서 미세 조정(fine-tuning)이라고도 불린다. 이러한 접근법은 많은 분야에서 실험적인 성과를 거뒀다. AlexNet을 처음부터 학습하려면 길게는 일주일 이상의 시간이 소요되는 반면, 전이 학습을 활용할 경우 몇 시간 안에 학습이 끝나기 때문이다.


심층학습에서의 전이 학습과 미세 조정

- 심층학습에서의 전이 학습(transfer learning)과 미세 조정(fine-tuning)은 모두 이미 학습된 인공신경망을 활용하는 점에서 공통점이 있음
- 이 둘의 차이점은 ImageNet의 AlexNet이나 ResNet을 활용하는 경우 다음과 같이 구별될 수 있음
- 전이 학습의 경우 이미 학습된 신경망의 가중치 전체를 재학습시키는 접근으로 새로운 데이터가 이미지 분류의 임무이나 ImageNet 데이터와의 성격이 상이할 경우 활용됨
- 미세 조정은 ImageNet과 유사한 데이터를 재학습하는 경우에 주로 활용되며, 구조적으로 마지막 fully-connected 층과 classifier 층을 연결하는 가중치만 재학습하는 방법으로 비용이 저렴함

심층학습에서의 전이 학습은 큰 의미에서 본질적인 전이 학습과 일맥상통하는 부분이 있으나 매우 제한적인 접근이다. 심층학습의 전이 학습은 이미 학습한 인공신경망을 바탕으로 새로운 데이터의 학습을 통해 새로운 임무를 해결한다는 측면에서 일부 공통점이 있다고 본다. 그러나 본질적인 전이 학습에서는 이미지를 분류하는 인공신경망의 지식이 전이되어 음성 인식에 적용된다는 것을 의미한다. 현재 전이 학습이라는 용어가 인공지능 연구계에서 혼재되어 사용되는 측면이 있기 때문에, 용어를 활용하는 데 있어 주의가 필요하다.

전이 학습은 개념 자체가 범용 인공지능에 맞물려 있기 때문에 현 시점에서는 매우 도전적인 과제다. 전이 학습과 관련된 대표적인 연구는 구글 딥마인드의 PathNet이 있다. PathNet은 인공신경망이 학습을 진행하면서 신경망의 어떤 부분이 새로운 임무(task)에도 재사용될 수 있을지를 탐색하는 기법이다. 신경망의 재사용(path로 표현) 가능성을 측정하기 위해 유전 알고리즘(genetic algorithm)을 활용했으며, 이것의 적합도를 판단하기 위한 비용함수를 제안했다. 특히 실험적인 결과를 통해 신경망의 재사용 가능성이 높은 인공신경망으로 새 임무를 학습한 효율이 미세 조정(fine-tuning) 방법보다 우월함을 증명했다.

[그림 7]은 PathNet의 구조를 나타낸다. 이 그림에서는 먼저 A라는 게임을 학습하기 위해 4개의 은닉층과 각 층 당 10개의 노드를 활용했다. 여기서 재사용 가능성이 높은 노드가 붉은색으로 표현되며, 이것을 활용해 B라는 게임을 학습한다면 효율이 올라간다는 의미다.



[그림 7] 전이학습의 예 : PathNet의 구조

자료 : Fernando, Chrisantha, et al. "Pathnet: Evolution channels gradient descent in super neural networks." arXiv preprint arXiv:1701.08734 (2017).

전이 학습은 앞서 소개한 스파이킹 신경망과도 관련이 있다. 스파이킹 신경망이 인공신경망의 전체를 활용한다기 보다 일부를 활용한다는 접근은 PathNet의 방법과 유사하다. 스파이킹 신경망이 전통적인 인공신경망 기법보다 뇌에 더 가까운 구조를 모사한다고 본다면, PathNet 역시 틀은 인공신경망이나 재사용의 관점에서 뇌의 구조적인 기능을 모사했다고 볼 수 있다. 또한 PathNet은 가장 먼저 소개한 메타 학습과도 맞물려 있다. 그 성능 역시 마찬가지다. 이 두 가지 연구의 궁극적인 목표는 범용 인공지능에 있기 때문이다.

현재 전이 학습의 연구는 여전히 같은 도메인 안에서의 전이(transfer)에 국한돼있다. 심지어는 데이터의 속성이 비슷해야 성공적인 전이가 이루어진다는 측면도 존재한다. 이러한 이유로 진정한 의미에서 도메인 간의 전이(transfer)가 이루어지기는 아직 요원한 일이라고 판단된다.

(5) 소 결

지금까지 네 가지 인공지능 기초연구의 사례를 살펴봤다. 먼저 기초연구의 공통점은 두 가지 특징으로 요약 할 수 있다. 첫 번째는 모두 인공신경망 기반의 접근 방법이다. 인공신경망은 동물의 뇌 신경계를 모사한 접근으로, 1980년대 주류를 이끌었던 방법론이었으나 데이터와 계산 자원의 한계로 인해 정체기에 진입했었다. 그러나 빅데이터의 출현과 저렴한 고성능 HW의 보급으로 인공신경망을 필두로 한 심층학습이 재조명됐다. 심층학습의 눈부신 성공으로 인해 현재 인공지능 기초연구 역시 심층학습의 성능을 향상시키는데 초점이 맞춰져 있다고 볼 수 있다. 이 성능을 향상시키는 방점은 앞서 소개한 심층학습의 한계를 극복하기 위한 것이다.

두 번째 특징은 인공지능 기초연구가 아직 초기단계에 머물러 있다는 점이다. 분석한 인공지능 기초연구는 궁극적으로 심층학습의 효율성과 범용성을 높이는 데 중점을 두고 있다. 그러나 효율성과 범용성 어느 측면에서도 아직 실험적인 단계이며, 많은 가정을 두고 도출한 결과다. 물론 심층학습 자체가 가지고 있는 기술적 한계를 고려하면 이러한 시도가 활발히 이루어진다는 면은 긍정적이라 볼 수 있다. 보통 R&D 단계에서 기초연구는 5년 이상의 장기과제가 대부분이다. 하지만 현재 심층학습이라는 키워드에 집중되고 있는 트렌드를 볼 때 2~3년 이내에는 기초연구에서 괄목할 만한 성과가 있을 것이라 기대된다.

인공지능 기초연구는 향후 인공지능의 방향을 좌우 할 수 있는 잠재력이 높다고 판단된다. 그만큼 달성하고자 하는 목표 역시 어렵다. 이 보고서에서 인공지능 기초연구를 중점적으로 다룬 것 역시 이러한 이유에서다. 현재 인공지능 연구의 영역에서 기초연구가 차지하는 비중은 그렇게 크지 않으나, 인공지능의 근본적인 성능을 높일 수 있다는 점에서 큰 의미가 있을 것이다.

4. 결 론

인공지능이 세 번째 황금기를 맞이하며 성공가도를 달리고 있다. 많은 연구자들이 이번 황금기만큼은 지속될 것이라고 희망찬 예측을 하고 있다. 현대 인공지능은 과거 두 번의 황금기와는 배경이 다르다. 빅데이터의 출현과 값싼 계산 자원의 보급으로 인공지능 자체가 발전하기 위한 기반이 다져졌기 때문이다.

그렇다면 인공지능의 세 번째 황금기가 어떤 식으로 지속되고 있는지에 대한 이해가 중요하다. 인공지능 기술의 체계적인 이해를 돕기 위해 이 보고서에서는 가설단계이지만 인공지능 연구 영역의 가설을 제안했다. 그 근거는 현재 인공지능과 관련된 R&D와 산업의 특성에서 도출했다. 심층학습의 근원지인 인공지능 기반연구, 심층학습을 활용해 각 산업계에서 적용하는 인공지능 활용연구, 심층 학습의 한계를 극복하기 위한 인공지능 기초연구가 그 주요 골자다.

특히 이 보고서에서는 파급력이 높은 인공지능 기초연구에 중점을 두고 연구 네 가지 사례를 분석했다. 물론 이것은 빙산의 일각에 불과하겠지만 인공지능 기초연구의 방향은 이해할 수 있을 것이다. 현재 인공지능 기초연구는 좁은 인공지능에 머물러 있는 심층학습의 범용성을 높이는 방향으로 진행되고 있다. 이것은 곧 차세대 인공지능 연구의 초석이자 응용·개발 연구에의 접목되어 성능을 향상시키는데 기여할 것이다. 인공지능 기초연구는 상당부분 범용 인공지능과 가까운 부분이 있으나, 인공신경망 기술에 중점을 두고 있다는 점에서 구별된다. 따라서 인공지능 기초연구가 어떠한 식으로 발전할지 그 귀추가 주목된다.

향후 연구로는 제안한 인공지능 연구 영역의 구분을 고도화하기 위한 작업이 진행될 것이다. 또한 심층학습을 촉발시킨 인공지능 응용분야에 대해서 주제별로 기술의 진척 상황을 분석해 볼 것이다. 인공지능은 지금도 끊임없이 발전하고 있다. 인공지능이라는 거대한 조류 속에 우리가 가장 먼저 할 수 있는 일은 기술의 발전상을 이해하는 것이라고 생각한다.

[별첨] 인공지능 기술 분류

1. IDC

대분류	세부분야
Hardware	Server, Storage
Software	Cognitive Application, Cognitive Platform
Service	IT Service, Business Service

자료 : Worldwide Semiannual Cognitive/Artificial Intelligence Systems Spending Guide, IDC(2017)

2. GVR (Grand View Research)

대분류	세부분야
Hardware	The hardware segment includes chipsets such as the Central Processing Unit (CPU), Graphics Processing Unit (GPU), Application-Specific Integrated Circuits (ASIC), Field-Programmable Gate Array (FPGA)
Software	AI-based software solutions include libraries for designing and deploying artificial intelligence applications including those for, inference, primitives, video analytics, sparse matrices, linear algebra, and multi-hardware communication capabilities.
Service	The service segment includes installation, integration, and maintenance & support undertakings

자료 : Artificial Intelligence Market Analysis(By Solution By Technology By End-use, By Region, and Segment Forecasts 2014 - 2025, AI Market, GVR(2017)

3. Gartner

대 분 류	세부 분야
Core AI Technology	Machine Learning, Deep Learning and Neural Networks Natural-Language Processing, Speech Recognition and Text to Speech, Computer Vision, Machine Reasoning, Decision Making and Algorithms, Business Analytics and Data Science, Robots and Sensors
Leading AI Application Areas	Bots, Chatbots and Virtual Assistants, Conversational AI Platforms, Analytics and Predictive Analytics Models, Smart Objects, Sensors and Environments
AI in the Enterprise	General Enterprise AI Strategies, Customer Service and Support, Digital Business Initiatives, Digital Commerce and Digital Commerce Personalization, Governance and Information Management for AI, Human Capital Management/Recruiting, Internet of Things, IT Service Monitoring/Help Desk, Legal, Ethical and Social Issues, Sales, Security and Fraud, Workplace and Digital Workplace
AI in Vertical Industries	Automotive, Banking, Asset and Wealth Management, Capital Markets, Business Process Outsourcing, Customer Management, Finance and Accounting Procurement, and HR, Consumer Products With AI, Government, Healthcare, Life Science and Pharma Education (K-12 and Higher Education), Insurance Services — Property, Casualty and Life, Invest/Venture Capital and AI, Manufacturing Operations, Retail, Supply Chain, Telecom, Topics Specific to Regional AI Usage

자료 : A Framework for Applying AI in the Enterprise, Gartner(2017)

[참고문헌]

1. 국외문헌

- Esser, S. K., et al. "Convolutional networks for fast, energy-efficient neuromorphic computing. 2016." Preprint on ArXiv. <http://arxiv.org/abs/1603.08270>. Accessed 27 (2016).
- Fernando, Chrisantha, et al. "Pathnet: Evolution channels gradient descent in super neural networks." arXiv preprint arXiv:1701.08734 (2017).
- Kulkarni, Santosh, Sishaj P. Simon, and Kinattingal Sundareswaran. "A spiking neural network (SNN) forecast engine for short-term electrical load forecasting." Applied Soft Computing 13.8 (2013): 3628-3635.
- Pham, Hieu, et al. "Efficient Neural Architecture Search via Parameter Sharing." arXiv preprint arXiv:1802.03268 (2018).
- Tavanaei, Amirhossein, et al. "Deep Learning in Spiking Neural Networks." arXiv preprint arXiv:1804.08150 (2018).
- Vinyals, Oriol, et al. "Matching networks for one shot learning." Advances in Neural Information Processing Systems. 2016.
- Zoph, Barret, and Quoc V. Le. "Neural architecture search with reinforcement learning." arXiv preprint arXiv:1611.01578 (2016).

2. 국내문헌

- 범용 인공지능의 개념과 연구현황, 이슈리포트 2018-002, 소프트웨어정책연구소 (2018)

3. 기 타

- Dartmouth workshop, https://en.wikipedia.org/wiki/Dartmouth_workshop
- Google Cloud AutoML, <https://cloud.google.com/automl/>
- Hebbian theory, https://en.wikipedia.org/wiki/Hebbian_theory

주 의

1. 이 보고서는 소프트웨어정책연구소에서 수행한 연구보고서입니다.
2. 이 보고서의 내용을 발표할 때에는 반드시 소프트웨어정책연구소에서 수행한 연구결과임을 밝혀야 합니다.