

2018. 5. 28  
(18-41호)

# KB 지식 비타민

**: 인공지능 알고리즘의 발전 방향과 금융산업 적용**

- ☐ 인공지능 알고리즘의 발전과 성과
- ☐ 인공지능 알고리즘의 한계와 진화 방향
- ☐ 알고리즘 활용 시 고려사항

## < 내 용 요 약 >

- 인공지능(Artificial Intelligence) 기술은 혁신적 알고리즘(algorithm)의 개발을 통해 인간과 유사한 방식으로 학습하는 진정한 의미의 인공지능으로 발전
  - 인공지능 알고리즘의 발전은 이미지 인식, 음성 인식 및 통·번역 등 다양한 영역에서 비약적인 성능 향상을 견인하고, 스마트 스피커 등 인공지능 서비스 상용화 확대
- 딥러닝 등 최신 알고리즘의 기업 활용을 어렵게 만드는 한계점이 존재, 이의 해결책을 모색
  - [정답이 있는 대량 데이터 필요] 데이터 없이도 반복적인 경험을 통해 정량화된 보상을 극대화하는 방법을 스스로 터득하는 ‘강화학습’ 및 실제와 매우 유사한 데이터를 직접 생성하는 ‘GAN’ 등 제시
  - [도출 결과의 설명력 부족] 딥러닝 등을 통해 도출된 결과값을 설명력 높은 모델과 결합하는 방식 (Surrogate 모형) 및 변수를 조정해 결과값의 변화를 파악하는 민감도 분석 방식(LIME) 등 제시
  - [기존 학습 모델의 재사용 어려움] 특정 영역에서 학습된 모델을 다른 유사 영역으로 이전하는 ‘전이 학습’ 및 해당 영역에 맞춤형된 인공지능 시스템을 자동으로 설계해 주는 ‘메타학습’ 등 연구
- 인공지능 알고리즘은 뚜렷한 한계점에도 불구하고 이에 대한 솔루션을 매우 빠른 속도로 찾아내고 있다는 점에서, 새로운 기술에 대한 지속적 학습 및 실제 적용이 요구

## ■ 인공지능(Artificial Intelligence) 알고리즘의 발전과 성과

- 인공지능 기술은 활용 가능한 데이터와 컴퓨팅 파워의 증대와 함께 혁신적 알고리즘(algorithm)의 개발을 통해 인간과 유사한 방식으로 학습하는 진정한 의미의 인공지능으로 발전
  - 2000년대까지 전문가 시스템(expert system) 등의 인공지능 기술은 인간이 만들어 놓은 지식을 기계에게 주입하는 방식(rule-based)으로 구현되어 왔으나, 다양한 상황에 대응 가능한 지식 개발의 어려움 등으로 인해 제한적으로 활용
  - 다층의 신경망(Deep Neural Network)을 학습하는 방법(Back-propagation<sup>1</sup>)의 개발과 함께 CNN(Convolutional Neural Network)<sup>2</sup>, RNN(Recurrent NN)<sup>3</sup> 등 ‘딥러닝(Deep learning)’ 알고리즘들이 등장, 대용량 데이터와 컴퓨팅 파워를 통해 실제로 구현되기 시작
  - ‘인간의 지식’이 아닌 ‘생각하는 방식’인 알고리즘을 제공함으로써, 기계가 데이터를 통해 스스로 자신만의 룰을 학습하는 인공지능 시대로 진입 → 중국 Baidu의 음성인식 기술(‘Deep Speech’)은 문법이 아닌 DNN/CNN/RNN 등 알고리즘에 기반해 성능 향상

<sup>1</sup> 예측값과 실제값의 오차(error)를 줄이기 위해 출력(output)층에서 입력(input)층의 역방향으로 움직이며 가중치를 수정하는 방법

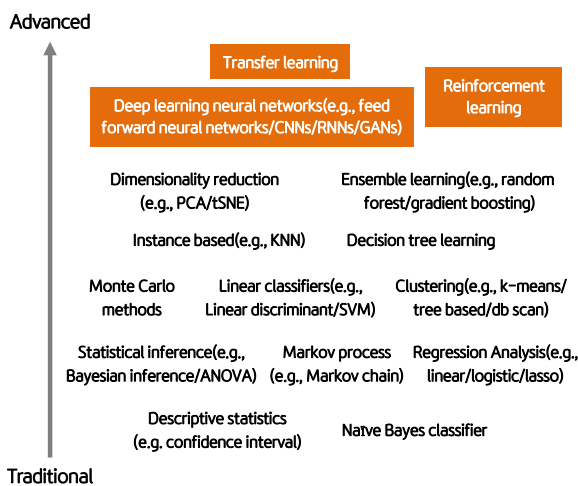
<sup>2</sup> ‘Object recognition with gradient-based learning’(Yann LeCun et al., Proceedings of the IEEE 1998)

<sup>3</sup> ‘Long short-term memory’(Sepp Hochreiter & Juergen Schmidhuber, Neural Computation 1997)

[표 1] 주요 딥러닝(Deep learning) 알고리즘 구조 및 개요

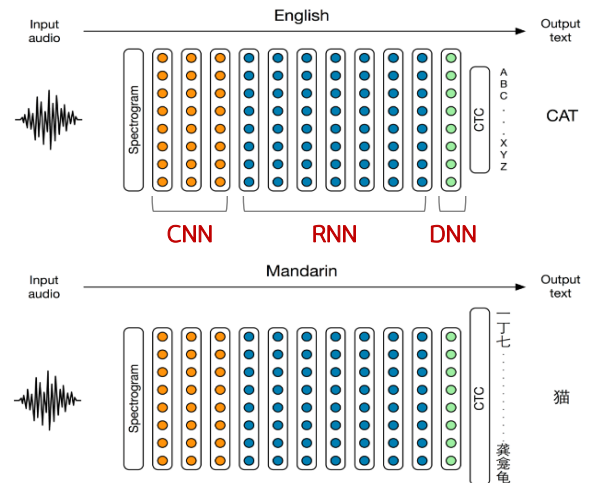
알고리즘	구조	개요
DNN		<ul style="list-style-type: none"> <li>· 인간의 신경망 시스템을 모방, 다층의 레이어(layer)와 다수의 인공 뉴런(neuron)을 결합해 복잡한 형태의 모형화 가능</li> <li>· Back-propagation(역전파) 방법을 통해 다층의 신경망 학습</li> </ul>
CNN		<ul style="list-style-type: none"> <li>· 이미지의 특징(feature)을 추출하는 필터 역할을 하는 ‘컨볼루션 레이어(Convolutional layer)’를 적용, 효율적 이미지 처리</li> <li>· 고차원의 이미지 인식(image recognition) 및 분류에 주로 활용</li> </ul>
RNN		<ul style="list-style-type: none"> <li>· 입력값(input)의 순서(sequence)를 고려하여 학습하는 모델</li> <li>· 현재의 입력값에 과거의 정보(state)를 결합하여 목표값 예측</li> <li>· 데이터의 순서가 중요한 시계열 분석 및 언어 처리 등에 활용</li> </ul>

[그림 1] 기술 수준별 인공지능 알고리즘



자료: McKinsey Global Institute analysis

[그림 2] Baidu ‘Deep Speech’ 시스템 구조



자료: Baidu(2016. 2)


○ 인공지능 알고리즘의 발전은 이미지 인식, 음성 인식 및 통·번역 등 다양한 영역에서 비약적인 성능 향상을 견인

- 딥러닝 알고리즘 활용 이후 이미지 인식의 정확도를 경쟁하는 ‘ImageNet Challenge’<sup>4</sup>에서 인공지능의 정확도가 인간의 인식률(94.9%)을 추월하기 시작
  - 인간 전문가가 만든 언어 모델(Ontology)에 기반한 음성 인식 기술은 80% 수준의 정확도를 달성하는데 10년 이상 소요되는 등 정체를 겪었으나, 딥러닝 알고리즘이 도입되면서 다수 언어의 인식 성능이 동시다발적으로 급격히 개선

<sup>4</sup> 1000가지 종류의 사물로 구성된 120만장의 이미지를 학습, 개별 이미지 속 사물의 종류를 맞추는(object localization) 경쟁


- 기술 성능의 획기적 발전과 함께 음성을 통해 디바이스와 상호 작용이 가능한 스마트 스피커(smart speaker) 등 인공지능 서비스의 상용화가 빠르게 확대
  - Amazon의 인공지능 기술 ‘Alexa’를 탑재한 스마트 스피커 ‘Amazon Echo’ 출시 이후 2년 만에 미국 성인 4,730만명이 스마트 스피커를 이용 중인 것으로 조사되는 등, Amazon·Google·Apple 등 거대 IT기업들이 경쟁하는 시장으로 성장
  - 딥러닝 알고리즘의 우수성이 검증됨에 따라 주변 환경을 빠르게 인식, 주행 방식을 판단해야 하는 자율주행차(self-driving car)의 현실화 가능성 증대

[그림 3] 이미지 인식의 성능 개선 추이



자료: ImageNet Challenge 결과

[그림 4] 세부 활동별 스마트 스피커 이용 빈도




자료: Voicebot.ai(2018. 3)

- 인공지능 기술이 숲 산업에 큰 영향을 미치는 ‘보편적 기술(General-Purpose Technology)’로 인식되면서, IT뿐만 아니라 소매업(retail)·미디어·금융 등 다양한 산업에서 기술 적용 사례 증가
- 2017년 3분기 상장기업 실적 발표(earnings call) 시 ‘인공지능’이 791회나 언급<sup>5</sup> 되는 등, 업종에 관계없이 인공지능 기술에 대한 관심이 커지는 모습
  - McKinsey<sup>6</sup>는 향후 20년간 인공지능 기술이 마케팅·영업(1.4조 달러), 공급사슬(supply chain) 관리(1.3조 달러), 리스크 관리(0.5조 달러), 고객서비스 운영(0.2조 달러), 재무·IT(0.2조 달러) 등 경영 전반에서 높은 부가가치를 창출할 것으로 예상
  - Foxconn·Nvidia 등의 정밀부품 제조기업들은 딥러닝 알고리즘을 적용한 컴퓨터 비전(computer vision) 기술을 활용, 제조 프로세스 상의 결함을 자동으로 파악하고 있으며, 영국 소매업체 Ocado는 하루 1만개 이메일의 고객 감정을 분석, 고객서비스 고도화

<sup>5</sup> ‘On earnings calls, big data is out. Execs have AI on the brain’(CBInsights, 2017. 11)<sup>6</sup> ‘Notes from the AI frontier insights from hundreds of use cases’(McKinsey Global Institute, 2018. 4)


- 금융산업은 현재 기술 도입 수준 및 향후 투자 수요의 측면에서 IT·통신, 자동차·부품 산업 등과 함께 인공지능 기술의 영향력이 높은 산업으로 평가
  - 글로벌 86개 은행들은 인공지능 기술이 향후 3년간 매출 3.4% 증가, 비용 3.9% 감소 효과를 가져올 수 있을 것으로 기대 (UBS Evidence Lab)
  - 헤지펀드(hedge fund) 시장의 전반적 약세에도 불구하고 인공지능 알고리즘을 통해 투자전략을 자동화하는 퀀트 펀드(Quant fund)는 자금이 순유입되는 흐름 지속 → 미 정부의 암호해독가로 일하던 James Simons는 헤지펀드 ‘Renaissance Technologies’<sup>7</sup>를 설립, 신호 처리와 음성 인식에 사용되는 인공지능 기술을 투자 전략에 적극 활용

[그림 5] 업종별 인공지능 침투율 및 향후 투자



자료: McKinsey(2017. 6, 10개국 경영진 조사)

[그림 6] 헤지펀드 자금유출입(net flow) 추이



자료: HRF(2017년은 9월까지의 데이터)

## ■ 인공지능 알고리즘의 한계와 진화 방향

### ○ 정답이 있는 대량의 학습 데이터 필요 (Obtaining labeled & massive training data sets)


- 다층의 레이어와 다수의 뉴런으로 구성된 인공신경망(artificial neural network)를 학습하는 딥러닝 알고리즘 등을 활용하기 위해서는 정답(결과값)이 존재하는 대량의 학습 데이터가 필요
  - 딥러닝 알고리즘은 우수한 수준(relatively good)의 분류(classification) 성능을 내기 위해서는 수천 개의 데이터가 필요하며, 사람과 비슷한 수준의 성능을 내려면 수백만 개의 데이터 요구<sup>8</sup>
  - 대부분의 알고리즘이 입력값과 결과값이 모두 이용되어야 하는 ‘지도학습(Supervised-learning)’ 방법론이기 때문에, 정답이 존재하는 데이터(labeled data)의 확보가 중요

<sup>7</sup> 연평균 30% 이상의 수익률을 15년 이상 지속한 ‘Medallion Fund’ 등 운용. 현재 500억 달러의 AUM으로 세계 4위 헤지펀드

<sup>8</sup> ‘Deep Learning’(Ian Goodfellow, Yoshua Bengio and Aaron Courville, 2016)

- [강화학습(Reinforcement learning)] 인공지능 시스템이 여러 번의 시행착오(trial and error)를 하는 과정에서 설계자가 원하는 특정 행동(action)을 할 때 보상(reward, 예: 높은 점수)을 제공, 누적 보상이 최대화되는 방법(optimal policy)을 학습하는 알고리즘
  - ‘지도학습’ 알고리즘이 요구하는 (행동  $x$ , 결과  $y$ ) 형태의 데이터가 주어지지 않더라도, 반복적인 경험을 통해 자신이 처한 상황과 행동 가능한 옵션들을 인지, 정량화된 보상을 극대화하는 방식을 스스로 터득

#### □ 인간의 지식을 학습하지 않고도 바둑을 마스터한 ‘AlphaGo Zero’<sup>9</sup>



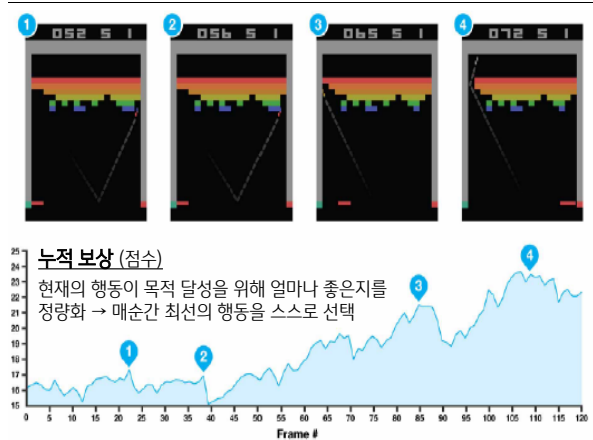
DeepMind는 인간이 만들어 낸 기보(데이터)를 배우지 않고도 ‘강화학습’을 해 단기간에 바둑 최고수의 실력을 습득한 ‘AlphaGo Zero’ 발표. 기본 규관을 알려준 후 다수의 실전 경험을 통해 바둑을 익힌 지 40일만에 2016 이세돌을 이긴 ‘AlphaGo Lee’의 실력을 넘어섬(100전 100승). 기보를 통한 학습한 알고리즘의 성능을 뛰어넘은 것은 ‘고정관념 등 인간의 오류가 포함된 데이터’가 학습에서 배제되었기 때문이라는 분석 존재

[표 2] 데이터 규모별 의료 이미지 분류 정확도

데이터 양	10	20	100	200
뇌(Brain)	3.39	45.71	72.82	98.44
목(Brain)	30.63	79.97	99.74	99.33
어깨(Shoulder)	21.39	69.64	95.53	92.94
가슴(Chest)	34.45	62.53	95.25	99.61
배(Abdomen)	3.23	35.40	91.01	95.18
골반(Pelvis)	1.15	15.99	83.70	88.45
평균	17.37	51.54	89.68	95.67

자료: Goldman Sachs (0(부정확)~100(정확))

[그림 7] 강화학습 기반 ‘벽돌깨기 게임’ 학습



자료: V. Minih(Nature, 2015)

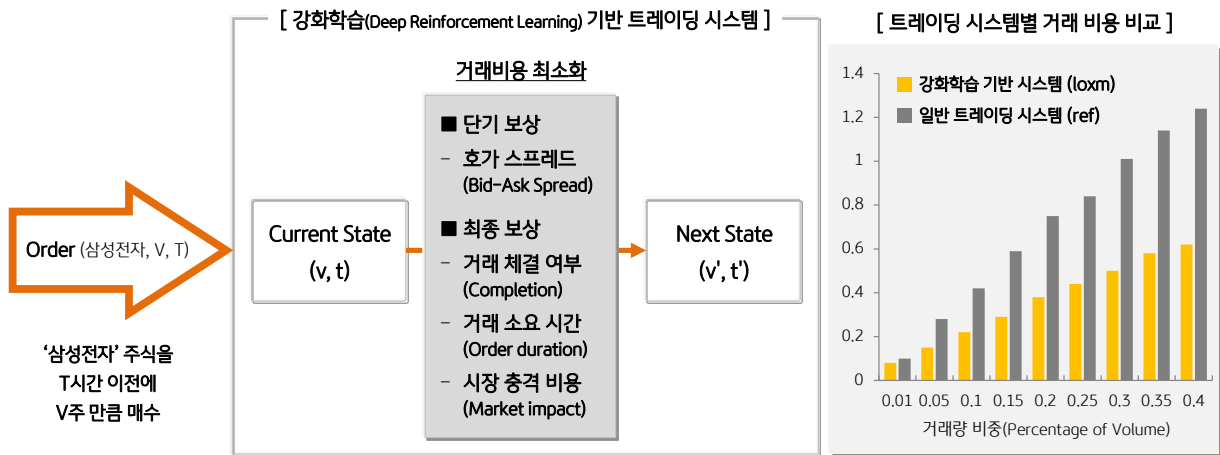
- JPMorgan은 단기 보상(호가 스프레드) 및 최종 보상(거래 체결 여부/거래 소요시간/시장충격 비용<sup>10</sup>)을 최소화(보상을 ‘비용’으로 정의)하도록 최적의 주식거래 전략을 학습하는 강화학습 기반의 트레이딩 알고리즘 ‘LOXM’ 개발<sup>11</sup> → 특히 대량의 주식 매도가 필요한 경우 시장에 미치는 충격(market impact)을 최소화함으로써 투자자의 거래 비용을 낮추는데 벤치마크 대비 탁월한 성과

<sup>9</sup> ‘Mastering the game of Go without human knowledge’ (David Silver et al., Nature 2017. 10)

<sup>10</sup> 대량의 주문을 일시적으로 실행할 때 단기적 거래가격 변화(일시적 충격) 또는 새로운 균형가격 도달(영구적 충격)로 인한 비용

<sup>11</sup> ‘Active Learning in Trading Algorithms’(JPMorgan) 및 ‘JPMorgan develops robot to execute trades’(FT, 2017/7/31)

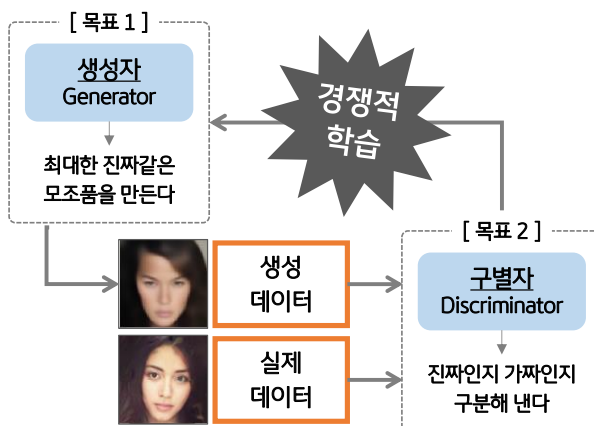
[그림 8] JPMorgan의 강화학습 기반 트레이딩 시스템 'LOXM' 개요 및 성능



자료: 'Active Learning in Trading Algorithms(JPMorgan, 2016)' 및 KB경영연구소

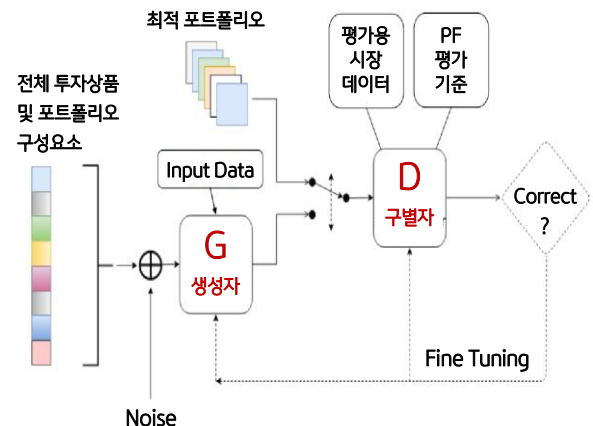
- [GAN(Generative Adversarial Network)] 실제와 비슷한 데이터를 생성하는 모델(Generator)과 이를 통해 생성된 데이터와 실제 데이터를 구별하는 모델(Discriminator)을 경쟁시켜, 두 모델의 학습 성능을 동시에 개선할 수 있는 알고리즘<sup>12</sup>
  - 실제와 매우 유사한 데이터를 직접 생성할 수 있기 때문에, 정답이 존재하는 데이터의 양이 부족한 환경에서도 학습 가능 → 이상거래(fraud)에 대한 데이터가 부족한 상황에서 GAN을 통해 실제 이상거래와 유사한 사례를 다수 생성, FDS(이상금융거래탐지시스템)의 고도화 가능<sup>13</sup>
  - Qraft Technologies는 GAN 알고리즘을 통해 실제 시장 내 최적 포트폴리오의 특성을 최대한 반영한 새로운 포트폴리오를 구성하는 'Q-GAN' 솔루션 개발

[그림 9] 'GAN' 알고리즘 개요



자료: Tech M 및 KB경영연구소

[그림 10] Qraft의 'Q-GAN' 포트폴리오



자료: Qraft Technologies(2017. 9)

<sup>12</sup> 'Generative Adversarial Networks'(I. Goodfellow et al., 2014)

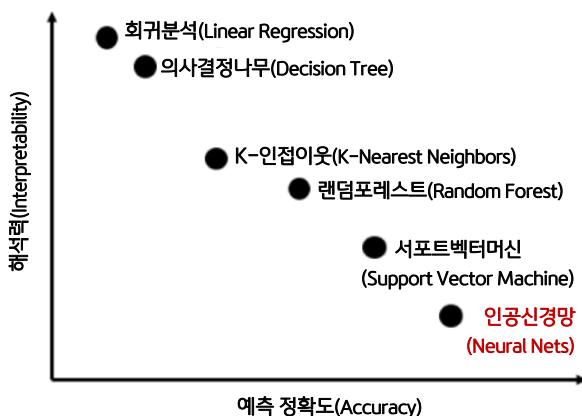
<sup>13</sup> 'Generative Adversarial Networks and Cybersecurity Part1/2'(SecurityIntelligence, IBM 2018. 3)



### ○ 해석력·설명력 문제 (The explainability problem)

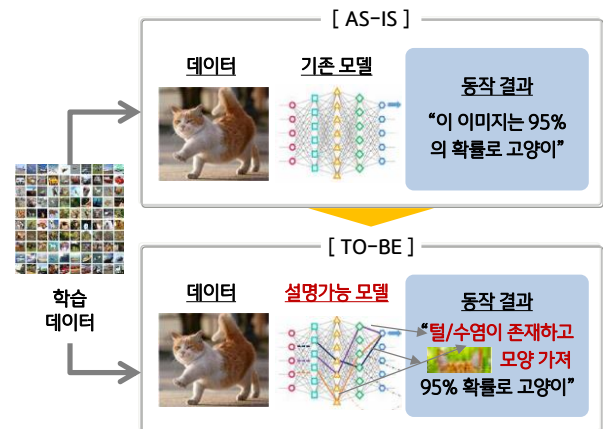
- 딥러닝 등 복잡한 구조의 인공지능 알고리즘들은 도출된 결과의 근거나 영향 변수 등을 확인하기 어려운 ‘블랙박스(Black box)’<sup>14</sup>의 속성을 가지므로 기업 활용 시 큰 제약요인
  - 알고리즘의 복잡성이 커질수록 예측의 정확도는 향상되나, 변수간의 다양한 상호작용(interaction effect)을 파악하기 어렵기 때문에 해석력(interpretability)은 하락
  - 의료·금융산업 등 서비스의 공정성 및 신뢰성이 매우 중요한 산업의 경우에는 알고리즘의 사용 변수, 결과의 도출 근거 등에 대한 설명을 제공할 책임 요구 → 올해 5월 유럽에서 시행된 GDPR(일반개인정보보호법)<sup>15</sup>은 알고리즘에 의한 자동화된 처리(automated decision making & profiling)에 대해 설명 요구, 이의 제기 등의 권리 부여
  - 인공지능의 사회적 영향력이 강화됨에 따라 미국 DARPA(방위고등연구계획국)는 2017년부터 인공지능 알고리즘의 해석 가능성을 높이기 위한 ‘XAI(eXplainable AI) 프로젝트’에 약 800억원의 예산을 투입

[그림 11] 해석력 vs. 정확도 기준 알고리즘 비교



자료: Ansaro Blog

[그림 12] DARPA의 'XAI' 개념



자료: DARPA 및 금융보안원 재인용

- [해석력 강화 모델] ①딥러닝을 통해 도출된 결과값을 설명력 높은 모델(회귀분석 등)과 결합하는 방식(Surrogate models), ②변수간 상호작용을 제한하는 방식(GAM), ③변수를 조정해 결과값의 변화를 파악하는 민감도 분석 방식(LIME) 등 다양한 알고리즘 연구
  - ① 딥러닝 등 정확성이 높은 모델을 통해 도출된 결과값을 회귀분석·의사결정나무 등 해석력 높은 모델(대리모형(surrogate models))의 종속변수로 활용, 딥러닝 알고리즘이 도출한 결과에 대한 근거 및 타당성 확인<sup>16</sup>

<sup>14</sup> 'Deep Learning: A Critical Appraisal'(Gary Marcus, 2018. 1)

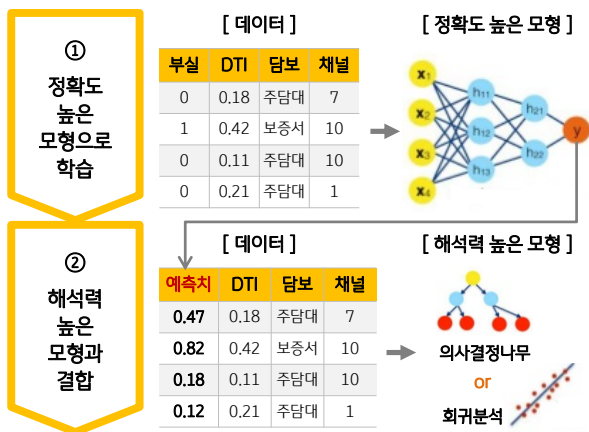
<sup>15</sup> General Data Protection Regulation: 자연인에 대한 개인정보를 보호하고 개인정보의 자유로운 이동 및 활용을 보장

<sup>16</sup> 'Ideas on interpreting machine learning'(Patrick Hall et al, O'REILLY conference 2017. 3)



- ② 개별 변수별로 복잡한 구조의 알고리즘을 적용한 후 이를 더하기 형태로 종합(GAM, Generalized Additive Models)함으로써, 변수간 상호작용 효과를 배제해 설명력 제고<sup>17</sup>
- ③ 특정 변수에 약간의 변화(perturbation)를 주었을 때 결과값이 어떻게 변하는지 확인함으로써 알고리즘이 도출한 결과값에 큰 영향을 미친 요인을 파악 → 특정 모델에 국한되지 않고 유연하게 활용 가능 (Local-Interpretable-Model-agnostic Explanations)

[그림 13] 대리모형(Surrogate models) 개요



자료: Patrick Hall et al.(O'REILLY, 2017)

[그림 14] 'LIME' 알고리즘 적용 사례

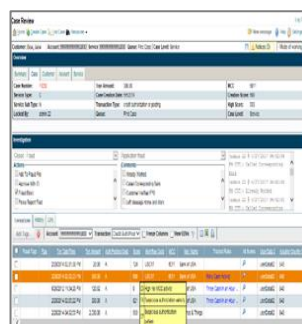


회색으로 가려진 부분은 해당 이미지가 입력값에서 삭제된 것  
얼굴과 눈 부분이 있을 때 개구리로 분류할 확률이 증가(85%)하고  
없을 때 거의 0으로 감소, '얼굴과 눈'이 개구리 분류의 핵심 요인

자료: Marco Tulio Ribeiro et al.(O'REILLY, 2016)

- 금융회사들은 예측 정확도 향상을 통한 수익성 제고와 높은 설명력에 기반한 신뢰성 제고가 동시에 요구되는 신용평가모형(Credit Scoring System) 개선 시, 해석력 높은 인공지능 알고리즘에 많은 관심

## □ 신용평가 기업 FICO의 'Reasons Reporter' (자료: FICO Blog)



국 다수 은행이 활용하는 신용평가점수를 제공하는 FICO는 인공지능망 기  
의 신용평가 및 이상카드거래탐지 시스템(Falcon Fraud Manager)을 개발하  
평가 결과의 설명력을 높이기 위해 'LIME' 알고리즘을 적용한 'Reasons  
'porter' 개발. 신용평가 및 이상카드거래 탐지 시 어떤 요인이 큰 영향을  
쳤는지 파악 가능. 해석력 높은 인공지능 알고리즘 개발을 촉진하기 위해,  
국방성 등과 함께 올해 5월 'xML Challenge' 개최

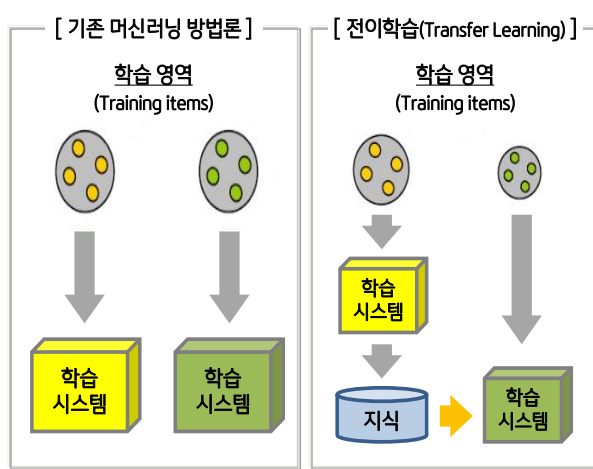
## ○ 학습 모형의 일반화 (Generalizability of learning)

- 특정 영역의 데이터에 최적화되도록 학습한 인공지능 모형은 속성이 유사한 다른 영역에 적용(generalization)하기 어렵기 때문에, 항상 새로운 모형을 개발해야 하는 비효율성 발생

<sup>17</sup> 'Intelligible models for classification and regression'(Yin Lou et al, ACM 2012)

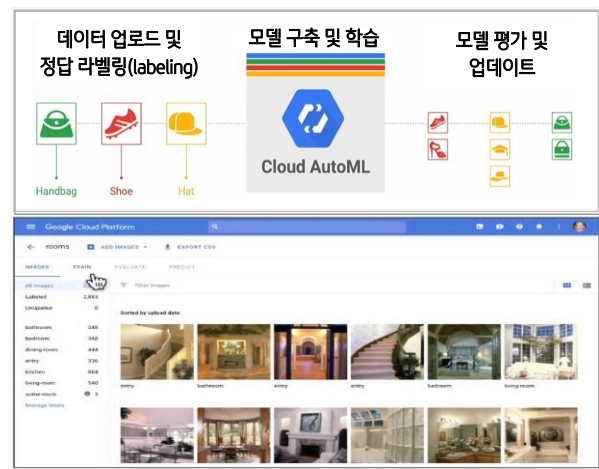
- 인간은 특정 분야에서 습득한 지식을 다양한 영역에 쉽게 활용할 수 있는 반면, 딥러닝 등 인공지능 알고리즘은 주어진 데이터에 자주 과적합(Overfitting)되기 때문에 다른 영역에서의 재사용 제한적<sup>18</sup>
- 인공지능 구현 시 기존에 학습된 지능을 활용한다면 학습 과정에서 요구되는 데이터와 컴퓨팅 비용을 획기적으로 절감할 수 있기 때문에, 지능의 이식(transferring intelligence)이 가능한 ‘범용 인공지능(General AI)’의 필요성 증대 → 바둑을 정복한 DeepMind의 AlphaGo Zero는 장기(2시간 학습), 체스(4시간 학습)에서도 기존에 가장 우수한 실력을 보인 소프트웨어의 실력 능가<sup>19</sup>
- [범용 인공지능 모델] ①특정 영역에서 학습된 모델을 다른 유사 영역으로 이전하는 ‘전이 학습(Transfer learning)’, ②해당 영역에 맞는 인공지능 시스템 설계를 자동화하는 ‘메타학습(Meta-learning)’ 등 연구 가속화
  - ① ‘전이학습’: 영역간 유사성(Similarity), 관련성(Relationality) 등을 추출, 데이터 확보가 용이해 충분히 학습된 기존 영역(source domain)의 지식을 새로운 영역(target domain)으로 이전하고, 해당 영역의 특성에 맞게 재학습(Re-training) → Volkswagen은 차선 유지·서행 등 자율주행을 위한 범용 지능을 우선 구축하고, 주행 우선순위·표지판 등 국가별 차이만을 재학습하는 방식 활용
  - ② ‘메타학습’: 다양한 영역의 데이터에 맞춤형 인공지능을 자동으로 구현해주는 인공지능 알고리즘 개발 → Google은 데이터만 있으면 자동으로 딥러닝 모델을 디자인해주는 ‘AutoML’ 서비스를 자사의 클라우드플랫폼(GCP)과 함께 제공

[그림 15] ‘전이학습(Transfer Learning)’ 개념



자료: Sinno Jialin Pan(2012. 5)

[그림 16] Google의 'Cloud AutoML'



자료: Google

<sup>18</sup> 'Deep Learning: A Critical Appraisal'(Gary Marcus, 2018. 1)<sup>19</sup> 'Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm'(DeepMind, 2017. 12)

- 금융회사들은 데이터가 풍부한 업권 및 국가 등에서 구축된 학습 모델을 데이터가 부족한 영역으로 전이(예: 은행의 콜센터 데이터 분석을 통한 챗봇 시스템 → 저축은행 챗봇)하는 방법에 초점

## ■ 알고리즘 활용 시 고려사항

- 인공지능 알고리즘은 자연어 처리(natural language processing), 이미지 인식 등 장기간 정체되었던 분야에서 비약적 성능 향상을 견인하였으나, 기업 활용 시 여전히 많은 한계점이 존재
  - 정답이 있는 대량의 학습 데이터 필요, 도출 결과의 설명력 부족, 기존 학습 모델의 재사용 어려움 등은 기업들이 딥러닝 등 최신 알고리즘의 활용을 주저하게 만드는 핵심 요인 → Google, Facebook 등 거대 IT기업들이 인공지능을 선도하는 이유도 데이터 및 기술 확보에 막대한 자금을 투여할 수 있는 자본력과 규제로부터 자유로운 환경의 영향이 크게 작용
  - 강화학습·GAN 등 이러한 한계점을 해결하기 위한 인공지능 알고리즘도 완벽한 솔루션은 아님 → 강화학습이 실제로 효과를 발휘하기 위해서는 학습 환경이 실제 환경의 복잡한 요인들을 잘 반영(representation of the real world)해야 하며, GAN 등을 통해 생성된 가상의 이미지를 통해 학습할 경우 실제 데이터를 통해 학습한 인공지능보다 성능이 저하되기도 함<sup>20</sup>
- 하지만 인공지능 기술은 자신의 한계를 스스로 극복하며 매우 빠른 속도로 발전하고 있다는 점에서 새로운 알고리즘에 대한 지속적 학습 및 적용이 요구
  - 2016년 발표된 인공지능 관련 논문은 1만8천건으로 1996년 이후 9배 이상 증가(일반 논문은 2배 수준)했으며, NIPS/CVPR/ICML 등 관련 컨퍼런스 참석자 수도 급증하는 추세<sup>21</sup> → 1998년 이후 Google(39.0억 달러)·Amazon(8.7억 달러) 등 15개의 대형 IT기업들은 총 86억 달러를 투자해 103개의 인공지능 스타트업을 인수하는 등 기업들도 적극적 투자<sup>22</sup>
  - RBC(Bank of Canada)는 2016년부터 캐나다 내 3개의 인공지능 연구소('Borealis AI')를 설립, 우수 인재 영입을 통한 전문적 연구 및 실무 적용 가능성 모색<sup>23</sup>

<선임연구위원 김예구(yeigoo.kim@kbfk.com) ☎02)2073-5764>

<sup>20</sup> 'Driving in the Matrix: Can virtual worlds replace human-generated annotations for real world tasks'(ICRA, 2017)

<sup>21</sup> 'Artificial Intelligence Index: 2017 Annual Report'(MIT & Stanford, 2017. 11)

<sup>22</sup> 'The 10 tech companies that have invested the most money in AI'(TechRepublic, 2018. 1)

<sup>23</sup> 'Non-tech 기업과 글로벌 금융회사의 AI 도입 사례'(KB경영연구소, 2018. 4)